

(가칭) Temporal Graph Neural Network와 강화학습을 통합한 하이브리드 인공지능 기반 포트폴리오 리밸런싱 의사결정지원 프레임워크

A Hybrid AI-Based Decision Support Framework Integrating Temporal Graph Neural Network and Reinforcement Learning for Portfolio Rebalancing

JoongHyun Park, Sehyun Kim, Junghyun Back, Hamin Kim, Donghyeok Kim, Hyun Lee

Abstract

디지털 전환과 인공지능(AI) 기술의 급속한 발전으로 의사결정 환경의 복잡성과 불확실성이 빠르게 증가하고 있다. 이에 따라 AI 기반 의사결정지원시스템(Decision Support Systems, DSS)의 중요성이 높아지고 있다. 본 연구는 금융 시장과 같이 동적이고 비정형적인 환경에서 지능적 의사결정을 지원하기 위한 신뢰할 수 있는(Trustworthy) 하이브리드 AI 기반 DSS 프레임워크를 제안한다.

제안된 시스템은 Temporal Graph Neural Network (TGNN)와 Deep Deterministic Policy Gradient (DDPG)를 고정 알파(Fixed Alpha, $\alpha = 0.5$) 균등 앙상블로 통합하여 포트폴리오 리밸런싱(Portfolio Rebalancing) 문제를 해결한다. 특히 본 연구는 단순한 성과 향상을 넘어, AI 의사결정의 재현성(Reproducibility)과 신뢰성(Reliability)을 보장하기 위해 결정론적(Deterministic) 알고리즘과 5개 독립 시드를 사용한 다중 시드 재현성 프로토콜(Multi-Seed Reproducibility Protocol)을 도입하였다.

S&P 500 구성 종목을 대상으로 약 19년간(2006-2025)의 데이터를 활용한 실험 결과, 제안된 Hybrid 모델은 장기 리밸런싱 주기(Quarterly, Semiannual, Annual)에서 Benchmark를 일관되게 상회하였으며, 특히 Annual 주기에서 CAGR 9.28%를 달성하였다. DDPG(Annual)가 최고 CAGR 10.41%를 기록했지만, 주기별 성과 편차가 커서 일부 구간에서 Benchmark를 하회한 반면, Hybrid 모델은 장기 투자 전략에 적합한 안정적 성과를 보여 학술 가치를 입증하였다. 또한 Flask 기반 AI 서버와 Spring-React 사용자 인터페이스를 통합하여 실시간 DSS 환경을 구현하였으며, TGNN Attention 기반 설명 가능성(Explainability) 기법을 통해 모델의 의사결정 과정을 투명하게 검증하였다.

본 연구는 예측 중심의 기존 DSS를 넘어, 관계 인식형(Structure-Aware)·재현 가능한(Reproducible)·설명 가능한(Explainable) 지능형 의사결정지원시스템의 새로운 표준을 제시한다.

Keywords

Decision Support Systems(DSS); Graph Neural Network (GNN); Reinforcement Learning(RL); Deep Deterministic Policy Gradient(DDPG); Temporal Graph Neural Network(TGNN); Reproducibility; Explainable Artificial Intelligence (XAI).

저널: Decision Support Systems (Elsevier, SCIE, IF $\approx$ 6.8)

논문 주제: Temporal Graph Neural Network와 강화학습을 통합한 하이브리드 인공지능 기반 포트폴리오 리밸런싱 의사결정 지원 프레임워크

초점: AI 모델링 중심 + DSS 통합 응용

형식: IMRaD 구조 (서론-관련연구-방법론-실험-결과-결론)

Temporal Graph Neural Network와 강화학습을 통합한 하이브리드 인공지능 기반 포트폴리오 리밸런싱 의사결정 지원 프레임워크

1. 서론

AI 기반 디지털 전환(Digital Transformation)이 가속화되는 환경에서, 의사결정의 복잡성과 불확실성이 빠르게 증가하고 있다. 이러한 변화에 따라 인공지능(AI) 기반 의사결정지원시스템(Decision Support Systems, DSS)의 중요성이 한층 높아지고 있다.

특히 금융 시장은 데이터의 복잡성, 비정형성, 그리고 높은 변동성으로 인해 전통적인 통계 기반 의사결정 모형의 한계가 명확히 드러나고 있다(Park & Han, 2024; Chen & Goetzmann, 2020). 이에 따라 복합 데이터 구조를 처리할 수 있는 딥러닝(Deep Learning) 및 강화학습(Reinforcement Learning) 기반의 DSS 연구가 활발히 이루어지고 있으며, 최근에는 종목 간 상관관계나 시장 네트워크 구조를 학습할 수 있는 그래프 신경망(Graph Neural Network, GNN)과 정책 최적화를 시행하는 강화학습(Reinforcement Learning, RL)을 결합한 하이브리드 DSS 프레임워크가 새로운 패러다임으로 주목받고 있다 (Al-Nassar et al., 2023; Zhang et al., 2024).

1.1 연구 배경 및 필요성

기존의 금융 DSS는 대부분 회귀분석, ARIMA, 혹은 LSTM 기반의 단일 시계열 예측 모델에 의존해 왔다. 이러한 접근법은 개별 종목의 수익률 예측에는 효과적이지만, 시장 구조적 상호작용, 다차원적 리스크 요인, 동적 정책 최적화를 반영하기 어렵다는 한계를 지닌다 (Wu et al., 2021).

최근 Decision Support Systems 저널은 AI 기반 DSS의 구조적 진화를 강조하고 있으며, 특히 비정형 네트워크 데이터 기반의 "관계형 DSS(Relational DSS)" 개념이 전통적인 규칙 기반 시스템의 한계를 극복할 새로운 접근으로 제시되고 있다. 또한 단순한 예측 성능뿐만 아니라, AI 모델의 결과를 신뢰할 수 있는지에 대한 "신뢰성(Trustworthiness)" 문제가 중요한 화두로 떠오르고 있다.

1.2 최근 연구 동향

AI DSS 관련 최신 연구는 크게 두 가지 방향으로 발전하고 있다.

첫째, AI 모델링 중심 DSS 연구에서는 머신러닝·딥러닝 모델을 DSS 구조에 통합하여 의사결정의 정확성과 적응성을 향상시키는 방향이 주목받고 있다. 예를 들어, Zhang et al. (2024)은 Transformer 기반 DSS를 통해 비정형 금융 텍스트 데이터를 통합하여 의사결정 품질을 높였으며, Lin et al. (2023)은 강화학습을 적용해 리스크 조정 수익률을 향상시키는 정책학습 기반 포트폴리오 DSS를 제안하였다.

둘째, AI DSS 응용 및 통합 연구에서는 AI 모듈을 DSS 환경 내에서 실시간으로 동작시키는 구조적 프레임워크 설계가 활발히 진행되고 있다. Park & Han (2024)은 Flask 기반 API 서버를 활용한 AI-DSS 통합 구조를 제안하여, 사용자 피드백 루프를 포함한 지속 학습(Continual Learning) 프로세스를 구현하였다.

그러나 이러한 연구들은 주로 모델의 수익률(Profitability)이나 예측 정확도(Accuracy) 향상에 집중하는 경향이 있으며, AI 모델이 일관된 결과를 산출하는지(Reproducibility), 다양한 환경에서도 신뢰할 수 있는지(Reliability)에 대한 검증은 상대적으로 부족한 실정이다.

1.3 연구 공백 및 문제 제기

이러한 발전에도 불구하고 다음과 같은 한계가 여전히 존재한다.

- (1) 대부분의 연구가 모델의 성능 극대화에 치중하여, 실험 결과의 재현성(Reproducibility)과 신뢰성 검증을 간과하였다.
- (2) 기존 DSS는 AI 모델을 예측 모듈로만 활용하여 의사결정의 상호작용 구조(예: 종목 간 관계)를 반영하지 못했다.

(3) 강화학습 기반 DSS 연구들은 예측 모듈과 정책 모듈을 독립적으로 운용하여, 시장 구조 학습과 포트폴리오 최적화를 투자 주기(Horizon)에 따라 동적으로 결합하는 앙상블 메커니즘이 부재하였다. 따라서, 관계 학습(Relationship Learning), 정책 학습(Policy Optimization)뿐만 아니라 신뢰할 수 있는 재현성(Reproducibility)을 갖춘 통합 AI DSS 프레임워크의 필요성이 제기된다.

1.4 연구 목적 및 기여

본 연구는 위의 한계를 해결하기 위해, Temporal Graph Neural Network (TGNN)와 Deep Deterministic Policy Gradient (DDPG) 알고리즘을 통합하고, 엄격한 재현성 프로토콜을 적용한 신뢰할 수 있는 하이브리드 AI DSS를 제안한다.

이 시스템은 다음 세 단계로 구성된다.

- (1) TGNN을 통해 시장 내 관계 구조를 학습하고,
- (2) DDPG를 통해 포트폴리오 비중 조정 정책을 강화학습 기반으로 최적화하며,
- (3) Deterministic Algorithm 및 Seed Fixing을 통해 실험의 완전한 재현성을 보장한다.

본 모델의 목적은 소형주 발굴이나 알파 종목 탐색이 아닌, 대형 우량주 중심의 포트폴리오에서 리밸런싱 비율을 안정적으로 최적화하는 데 있으며, 실험 유니버스를 S&P 500 구성 종목으로 한정하는 것은 실제 기관 투자자 및 개인 투자자의 투자 행태와 일치하는 현실적 설정이다.

실험 전체 기간(2006-2025) 동안 상장이 유지된 종목만을 선정한 것은 Survivorship Bias에 대한 우려를 고려한 결과이나, S&P 500은 시가총액, 유동성, 재무 건전성 등 엄격한 편입 기준을 충족한 종목만으로 구성되어 해당 종목의 상장폐지 발생 빈도가 전체 시장 대비 현저히 낮다. 실제로 Russell 3000 기준 연간 상장폐지율이 약 3-5% 수준인 데 반해, S&P 500 편입 종목의 연간 상장폐지율은 0.1% 미만으로 보고되며, S&P 500은 구성 종목을 분기별로 재검토하여 재무 기준 미달 종목을 선제적으로 교체하므로 개별 종목의 완전한 상장폐지보다는 지수 제외(index exclusion) 형태로 리스크가 관리된다. 이처럼 S&P 500 유니버스 내에서의 생존 편향은 전체 시장 대비 그 영향이 제한적이며, 본 연구의 핵심 평가 지표인 포트폴리오 수익률과 샤프 지수에 미치는 편향 효과는 최소화된다. 나아가 본 연구는 개별 종목의 절대 수익을 예측하는 것이 아니라 종목 간 rebalancing ratio를 학습하는 모델을 평가하므로, 생존 편향에 의한 절대 수익 과대 추정 문제가 직접적으로 적용되지 않는다. 또한 섹터 다각화를 통해 특정 산업군에 편중되지 않는 일반화 가능한 포트폴리오를 구성하였다.

이를 통해 본 연구는 다음과 같은 기여를 한다:

- ① 신뢰할 수 있는 AI DSS 표준 제시: 단순 성능 우위를 넘어, 결정론적(Deterministic) 알고리즘과 시드 고정(Seed Fixing)을 통해 언제나 검증 가능한 재현성(Reproducibility)을 확보한 AI 연구 방법론을 제시한다.
- ② AI 모델 통합형 DSS 설계: 예측(TGNN)과 정책(DDPG)을 Fixed Alpha($\alpha = 0.5$) 균등 앙상블로 결합하는 통합형 DSS 아키텍처를 제안한다. 이는 동적 가중치 학습 방식 대비 시드 의존성을 제거하고 결정론적 재현성을 보장하는 설계 선택이다.
- ③ AI DSS의 실시간 자동화 구현: Flask-Spring-React 기반의 시스템 통합을 통해 사용자 피드백이 실시간으로 AI 정책 업데이트에 반영되는 구조를 구현한다.
- ④ 학문적·실무적 시사점 제시: 학문적으로는 AI DSS의 구조적 확장을 제시하고, 실무적으로는 금융 의사결정에서 설명 가능(Explainable)하고 자동화된 지능형 DSS(Automated Intelligent DSS)의 가능성을 입증한다.

2. 관련 연구 (Related Works)

2.1 AI 기반 의사결정지원시스템의 진화 (Evolution of AI-Based Decision Support Systems)

최근 DSS 분야는 단순한 규칙 기반(rule-based) 시스템에서 인공지능(AI) 기반의 지능형 의사결정지원(Intelligent Decision Support)으로 빠르게 발전하고 있다. Decision Support Systems 저널의 Lee and Kim (2023)은 AI 기반 의사결정엔진을 도입함으로써 전통적 분석형 DSS의 한계를 보완할 수 있음을 보였다. Applied Intelligence의 Gu et al. (2025)는 강화학습(RL) 엔진을 DSS 아키텍처에 내재화하여 시장 변화에 실시간 대응할 수 있는 AI-driven 의사결정엔진을 제시하였다. 또한 Information Sciences의 Bai et al. (2023)은 딥러닝을 활용한 의사결정지원 프레임워크를 검증하며, AI 모델이 비정형 데이터에서 의미 추론과 정책 추천을 수행할 수 있음을 입증하였다.

이처럼 최근 연구들은 AI 기술을 DSS의 핵심 요소로 간주하며, 예측 정확성뿐 아니라 설명가능성(Explainability) 및 적응성(Adaptivity)을 동시에 강조하는 방향으로 진화하고 있다 (Park & Han, 2024; Zhang et al., 2024). 그러나 대부분의 연구가 단일 AI 모델 중심 예측에 머물러 있으며, 다중 AI 모델 간 상호작용 또는 실험 결과의 재현성(Reproducibility)에 대한 체계적 검증은 아직 부족한 실정이다.

2.2 강화학습 기반 의사결정지원 (Decision Support with Reinforcement Learning)

강화학습(RL)은 비정형 환경에서 스스로 정책을 학습하는 능력으로 DSS 분야에 적극적으로 도입되고 있다. Neural Computing and Applications의 Lin et al. (2023)은 DDPG 모델을 적용한 DSS 프레임워크를 통해 비용-효율적인 포트폴리오 리밸런싱 정책을 학습하였으며, Knowledge-Based Systems의 Al-Nassar et al. (2023)은 Transformer 기반 정책 네트워크를 RL과 결합해 시계열 상관관계를 반영하였다.

최근 목표 지향적 연속 제어(Continuous Control)가 요구되는 비정형 환경에서는 Actor-Critic 구조의 효과성이 입증되고 있다. 일례로 Liu et al. (2024)은 로봇 네비게이션 문제에서 상태-행동-보상 구조를 정교하게 설계하여 동적 장애물 환경에 실시간으로 적응하는 Actor-Critic 모델(SAC)을 제안하였다.

본 연구는 Liu et al. (2024)가 제시한 '연속 제어 기반의 동적 환경 적응 메커니즘'의 개념적 타당성에서 착안하여, 이를 금융 의사결정 프레임워크로 차용한다. 구체적으로는 기존 로봇 네비게이션에서 활용된 MDP(Markov Decision Process) 설계 방식을 '시장 상태-포트폴리오 비중 조정-수익률/리스크 보상'의 체계로 변환하여 적용하였다. 다만 정책(Policy) 알고리즘의 선택에 있어서는, 탐색에 초점을 맞춘 확률적 정책(SAC)이 아닌, 자산 배분의 일관성과 학술적 재현성(Reproducibility)을 강력히 보장할 수 있는 결정론적 정책 알고리즘인 DDPG(Deep Deterministic Policy Gradient)를 채택한다. 본 연구는 이 DDPG 모델의 Actor-Critic 네트워크를 TGNN 임베딩과 결합함으로써, 시장 변동성에 강건하면서도 신뢰할 수 있는 관계 인식형 포트폴리오 최적화를 구현한다.

Decision Support Systems의 Zhang et al. (2024)은 PPO와 TD3 알고리즘을 비교하여 AI 정책이 리스크 관리 측면에서도 효율적으로 작동함을 보였다.

이와 같이 RL 기반 DSS 연구들은 의사결정의 자동화 수준을 높였지만, 대부분이 단일 정책 학습에 국한되어 예측 모듈과 정책 모듈을 투자 주기에 따라 동적으로 결합하는 앙상블 메커니즘은 부재하였다. 본 연구는 이러한 한계를 극복하기 위해 TGNN 기반 관계 학습과 DDPG 기반 정책 최적화를 고정 알파(Fixed Alpha, $\alpha = 0.5$) 균등 앙상블로 통합하여, 재현성이 강력히 보장된 하이브리드 기법을 제안한다.

2.3 그래프 신경망 기반 관계 학습 (Relational Learning with Graph Neural Networks)

복잡한 금융 데이터 환경에서 관계적 정보를 모델링하기 위해 그래프 신경망(Graph Neural Networks, GNN)이 핵심 도구로 자리잡고 있다. IEEE Transactions on Knowledge and Data Engineering의 Wu et al. (2021)은 GNN이 비유클리드 데이터의 관계 패턴을 정확히 학습할 수 있음을 보였고, ACM CIKM의 Xiang et al. (2022)은 Temporal GNN을 적용해 시장 동조화 효과를 모델링하였다. 또한 Economic Modelling의 Gong et al. (2025)은 Attention 기반 시공간 그래프 컨볼루션 모델을 활용하여 시장 간 변동성 예측 정확도를 향상시켰다.

그러나 기존 연구들은 GNN 출력을 단순한 예측 모듈로만 활용하며, 이를 의사결정 정책 최적화 단계(RL 또는 DSS 모듈)로 직접 연결한 사례는 거의 없다. 본 연구는 TGNN으로부터 얻은 관계 임베딩을 강화학습의 상태공간(State Space) 입력으로 활용하여, 관계 인지형(Relationship-Aware) DSS의 새로운 구조를 제시한다.

2.4 AI DSS 시스템 통합 연구(System Integration of AI Modules)

AI 기반 모델을 DSS 환경에 실시간으로 통합하는 연구는 아직 초기 단계에 머물러 있다. Decision Support Systems의 Park and Han (2024)은 Flask API와 React UI를 활용한 AI DSS 시스템 아키텍처를 설계하고, 사용자 피드백 루프를 통해 모델 성능을 지속적으로 갱신할 수 있음을 보였다. 또한 Applied Intelligence의 Gu et al. (2025)은 강화학습 모듈을 DSS의 실행 엔진으로 통합하여 정책 결정과 결과 분석이 자동화되는 구조를 제시하였다.

이러한 통합형 AI DSS는 데이터 수집-분석-정책결정-피드백-재학습의 순환형 프레임워크를 실현함으로써, 기존 단방향 의사결정 시스템의 한계를 극복한다.

2.5 요약 및 연구 차별성

비교 항목	기존 연구	본 연구의 차별성
AI DSS 구조	단일 모델 예측형 DSS	TGNN-DDPG 고정 알파(Fixed Alpha) 균등 앙상블 DSS
정책 학습	수익률 중심	리스크 조정 보상 + 결정론적 균등 앙상블 최적화
관계 학습	예측 모듈로 한정	관계 임베딩을 정책 학습 입력으로 활용
실험 신뢰성	성능 우위 강조 (Robustness)	재현성 프로토콜 적용 (Reproducibility & Seed Fixing)
시스템 통합	오프라인 모델 중심	실시간 API 연동형 DSS 통합 구조
해석 가능성(XAI)	일부 후처리 분석	Temporal & Stock-Level Attention 기반 설명 제공

요약하면, 본 연구는 AI 모델링과 DSS 시스템 통합을 유기적으로 결합하여, 예측 모듈과 정책 제어 모듈이 균등 앙상블 기반으로 작동하는 지능형 AI DSS 프레임워크를 제안한다. 또한, 결정론적 알고리즘을 도입하여 학술적 재현성을 보장함으로써 신뢰할 수 있는 연구 결과를 제시한다.

3. 제안 모델 (Proposed Hybrid AI Model)

3.1 개요 (Overview)

본 연구는 관계 학습(Relational Learning)과 정책 최적화(Policy Optimization)를 통합한 하이브리드 인공지능 기반 의사결정지원시스템(AI-based Decision Support System, AI-DSS)을 제안한다.

제안된 프레임워크는 Temporal Graph Neural Network (TGNN)와 Deep Deterministic Policy Gradient (DDPG) 두 모듈을 결합한 하이브리드 에이전트(Hybrid Agent) 구조를 기반으로 하며, 예측-결정-실행의 연속 피드백 루프를 형성한다. AI DSS의 전체 구조는 Figure 1과 같이 데이터 수집-관계 학습-정책 최적화-비용 최소화-의사결정 피드백의 순환 구조로 구성된다.

이 프레임워크는 단순한 데이터 분석을 넘어 시장의 구조적 상호작용을 학습하고, 강화학습 기반 의사결정을 자동화하며, DSS 내 실시간 정책 피드백을 가능하게 한다. 특히 본 연구에서는 기존의 단일 통합 모델 구조를 개선하여, 독립적인 DDPG와 TGNN 인스턴스를 고정 알파(Fixed Alpha, $\alpha = 0.5$) 균등 앙상블로 결합하는 Fixed-Weight Ensemble 메커니즘을 도입하였다.

3.1.1 자산 무관형 아키텍처 (Asset-Agnostic Architecture)

본 연구의 핵심 기여 중 하나는 자산 무관형(Asset-Agnostic) 구조의 도입이다. 기존 포트폴리오 모델들이 고정된 수의 주식(N)에 대해 학습하여 유니버스 변경 시 재학습이 필요한 것과 달리, 제안된 모델은 가변적인 시장 상황(Variable N)에 유연하게 대응한다. 이는 Shared Encoder(공유 가중치)와 Deep Sets (집합 연산) 기술을 적용하여 달성된다.




Figure 1. Proposed Hybrid AI-DSS Framework Architecture

3.2 관계 학습 모듈: Temporal Graph Neural Network (TGNN)

TGNN은 Kipf & Welling (2017)이 제안한 Graph Convolutional Network(GCN)를 시간축으로 확장하여, 시장 내 주식 간 동적 상관구조를 학습한다. 시점 t 에서의 그래프 G_t 는 노드 V (주식), 엣지 E_t (관계)로 구성된다. 엣지 가중치는 피어슨 상관계수와 산업 유사도를 결합해 산출된다.

3.2.1 Context-Aware Dual-Path Encoder

본 연구에서는 가격 데이터와 거시경제 지표를 분리 처리하는 Dual-Path Encoder 구조를 채택하였다.

Path A - Local Price Encoder: 종목별 가격 시계열 $\mathbf{X} \in \mathbb{R}^{(B \times N \times T \times 5)}$ 은 다음 절차로 처리된다.

1. Linear Projection + Layer Normalization: 각 시점 t 에서 OHLCV 5차원 입력을 선형 투영하여 128차원 임베딩으로 변환한다.

$$h_t = \text{LayerNorm}(W_{proj} \cdot \mathbf{x}_t + \mathbf{b})$$

2. 2-Layer GCN with Residual Connection: 투영된 노드 특징에 그래프 합성곱을 적용하여 종목 간 공간적 관계를 학습한다. 그래프 합성곱 연산은 다음과 같이 정의된다:

$$H^{(l+1)} = \sigma \left(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^{(l)} W^{(l)} \right)$$

여기서 $\tilde{A} = A + I$ 는 자기 연결이 추가된 인접행렬, $\tilde{D}$ 는 차수행렬이다. 차원 호환 시 잔차 연결(Residual Connection)을 적용하여 기울기 소실을 방지한다. GCN은 두 층($128 \rightarrow 128 \rightarrow 64$)으로 구성된다.

3. Multi-Head Temporal Self-Attention: 전체 시계열 T 스텝의 GCN 출력을 쌓아 $[B, T, N, 64]$ 형태로 구성한 뒤, Multi-Head Self-Attention을 적용하여 시간적 의존성을 포착한다. 이를 통해 최종 노드 임베딩 $E_{local} \in \mathbb{R}^{(B \times N \times 64)}$ 을 산출한다.

Path B - Global Macro Encoder: Fama-French 5-Factor $F \in \mathbb{R}^{(B \times N \times T \times 5)}$ 는 마지막 시점($t = T$)의 값을 추출하여 2층 MLP로 처리한다.

$$E_{macro} = \text{ReLU}(W_2 \cdot \text{ReLU}(W_1 \cdot F_T + b_1) + b_2) \in \mathbb{R}^{(B \times N \times 32)}$$

거시경제 지표는 시장 전체에 동일하게 적용되는 체계적 리스크(Systematic Risk) 신호로, 마지막 시점의 팩터 값이 현재 시장 국면(Market Regime)을 가장 직접적으로 반영한다.

Fusion: 두 경로의 출력을 연접(Concatenation)하여 96차원의 융합 임베딩 $E_{fused} = [E_{local} \parallel E_{macro}] \in \mathbb{R}^{(B \times N \times 96)}$ 을 생성하며, 이를 이후 예측 헤드의 입력으로 활용한다.

3.2.2 Multi-Head Prediction & Loss Function

4가지 기간(1개월, 3개월, 6개월, 12개월)의 가격 모멘텀을 동시에 예측하는 멀티 태스크(Multi-Task) 구조를 채택하였다. 손실 함수는 절대 오차와 상대 순위를 모두 고려한 복합 손실을 사용한다.

$$L = \alpha \cdot L_{MSE} + \beta \cdot L_{Ranking}$$

여기서 $\alpha = 0.7$, $\beta = 0.3$ 이며, Ranking Loss는 A가 B보다 수익률이 높으면, 예측값도 $A > B$ 여야 한다는 쌍별 순위를 수식화한다.

3.3 정책 학습 모듈: Deep Deterministic Policy Gradient (DDPG)

정책 학습 모듈은 자산 무관형(Asset-Agnostic) 강화학습을 수행한다.

(1) Asset-Independent Representation Learning: 주식 시장은 시간이 지남에 따라 유니버스에 편입되는 자산의 수(N)가 가변적이므로 고정된 차원의 네트워크 처리가 어렵다. 본 연구는 이러한 상태 공간의 비고정성을 극복하기 위해, 가중치 공유(Weight Sharing) 기반의 공유 인코더(Shared MLP)를 도입하였다. 이를 통해 개별 자산의 시계열은 자산 독립적인 공통 잠재 공간(Latent Space)으로 투영되며, 에이전트는 특정 자산에 고착 및 과적합(Overfitting)되지 않고 보편적 시장 동학(Universal Market Dynamics)을 학습할 수 있다.

(2) Continuous Policy Distribution and Entropy Regulation: 강화학습 에이전트의 정책(Policy) 행동은 자본 제약 조건($\sum W_i = 1, W_i \geq 0$)을 만족하는 연속적 포트폴리오 비중이어야 한다. 제안 모델은 잠재 표상으로부터 각 자산의 상대적 투자 매력도를 스칼라 값 산출 후, Temperature-scaled Softmax 함수를 통해 정책 분포(W_i)를 형성한다. 여기서 온도 파라미터($\tau = 3.0$)는 정책의 엔트로피(Entropy)를 제어하는 정규화(Regularization) 기제로 작용하며, 지식 탐색(Exploration)과 수확(Exploitation) 간의 수학적 균형을 맞춰 포트폴리오의 분산도를 제어한다.

$$W_i = \frac{\exp(s_i/\tau)}{\sum_{j=1}^N \exp(s_j/\tau)}$$

(3) Permutation-Invariant Portfolio Value Estimation: 통합 포트폴리오의 예상 가치(Q-value)를 평가하는 Critic 신경망은, 포트폴리오 구성 자산의 입력 순서가 변경되더라도 동일한 가치를 산출해야 하는 순열 불변성(Permutation-Invariance)을 요구한다. 이를 수학적으로 보장하기 위해 본 연구는 집합 연산에 기반한 Deep Sets 아키텍처(Zaheer et al., 2017)를 채택하였다. 로컬 수준에서 평가된 개별 특징(ϕ)을 전역 변수로 합산(Aggregation)하고 글로벌 신경망(ρ)을 통해 최종 가치를 평가하므로, 포트폴리오 크기가 변하더라도 모델 구조의 변경 없이 일관된 시스템 가치 추정이 보장된다.

$$Q(S, A) = \rho\left(\sum_{i=1}^N \phi(s_i, a_i)\right)$$

여기서 ϕ 는 로컬 인코더, ρ 는 글로벌 Q-Head이다.

본 연구의 실제 시스템 구현 시, 위에서 설명된 세 가지 핵심 모듈은 전체 시스템 통합을 위해 각각 `'SharedFactorEncoder'`, `'ScoreHead'`, `'DeepSetsCritic'` 클래스로 명명되어 개발되었다.

3.4 Hybrid Alpha & System Integration

세 모듈은 Python 기반 Flask API 서버에서 AI 엔진으로 작동하며, Spring Boot 백엔드와 React 프론트엔드를 통해 DSS 대시보드로 통합된다.

3.4.1 Fixed Alpha Ensemble

본 연구는 TGNN(예측 기반)과 DDPG(정책 기반)의 출력을 선형 결합하는 앙상블 메커니즘을 채택한다. 최종 포트폴리오 비중 W_{final} 은 다음과 같이 정의된다

$$W_{final} = \alpha \cdot W_{TGNN} + (1 - \alpha) \cdot W_{DDPG}$$

여기서 $\alpha = 0.5$ 는 로 고정하여 두 모듈의 기여도를 균등하게 설정한다. 이 설계 결정은 두 가지 근거에 기반한다.

첫째, 재현성(Reproducibility) 보장이다. 동적으로 학습된 α 는 강화학습 훈련 과정의 확률적 특성

(Stochasticity)에 민감하게 반응하여, 동일 모델이라도 학습 시드(Seed)에 따라 앙상블 가중치가 크게 달라질 수 있다. 본 연구의 예비 실험(Pilot Study)에서 Dynamic Alpha 설정은 일부 리밸런싱 주기에서 시드 간 CAGR 표준편차가 평균을 초과하는 불안정성을 보였다. 고정 알파는 이러한 시드 의존성(Seed Dependency)을 제거하여 실험의 결정론적(Deterministic) 재현성을 확보한다.

둘째, 모듈 간 기여도 공정성(Fairness)이다. $\alpha = 0.5$ 는 TGNN의 관계 예측 신호와 DDPG의 정책 최적화 신호에 동등한 가중치를 부여함으로써, 특정 모듈에 대한 사전 편향(Bias)을 배제하고 두 모듈의 상호보완적 특성이 최대한 발현되도록 한다. 이는 앙상블 이론에서 개별 모델의 오차가 독립적일 때 균등 가중치가 최적 분산을 달성한다는 이론적 근거(Brown et al., 2005)와 일치한다.

이를 통해 한 모듈이 다른 모듈을 압도(Dominate)하는 Mode Collapse를 방지하며, 두 모듈의 장점이 균형 있게 통합된다.

3.5 제안 모델의 구조 요약

모듈	주요 역할	핵심 기술	DSS 기여도
TGNN	관계 학습	Multi-Head GCN + Temporal Attn	시장 구조 및 추세 동시 학습
DDPG	정책 최적화	Asset-Agnostic (Shared Weights)	가변 유니버스 대응 및 최적화
Ensemble	통합 제어	Fixed Alpha ($\alpha = 0.5$)	두 모듈의 균등 기여 및 재현성 보장
통합 시스템	DSS 운영	Flask-Spring-React 구조	실시간 피드백 & XAI

Table 1. 하이브리드 AI DSS 모듈별 역할 및 핵심 기술 요약

4. 실험 설계 (Experimental Design)

4.1 데이터셋 구성 (Dataset Description)

본 연구에서는 2006년 1월부터 2025년까지의 글로벌 주식 시장 데이터를 활용하였다. 학습 기간(Train)은 2006-2020년, 테스트 기간(Test)은 2021-2025년으로 설정하였다. 포트폴리오 구성 종목은 S&P 500 지수의 구성 종목 중 GICS(Global Industry Classification Standard) 섹터 다각화 원칙에 따라 체계적으로 선정하였다.

4.1.1 종목 선정 방법론 (Stock Selection Methodology)

포트폴리오 종목 선정은 다음의 절차를 통해 수행되었다.

(1) S&P 500 종목 자동 수집: Wikipedia의 S&P 500 구성 종목 리스트를 자동 크롤링하여 전체 후보군을 확보하였다. 각 종목의 GICS 섹터 및 세부 산업 정보는 크롤링 데이터와 yfinance API를 통해 교차 검증하였다.

(2) Survivorship Bias 방지 필터링: 실험의 타당성을 확보하기 위해, 전체 실험 기간(2006-2025) 동안 상장이 유지된 종목만을 대상으로 하였다. 구체적으로, Train 기간(2006-2020)에 최소 1,000 거래일, Test 기간(2021-2025)에 최소 600 거래일의 데이터를 보유한 종목만 후보로 선정하였다.

(3) 섹터별 균등 추출: 포트폴리오의 위험 분산 효과를 극대화하기 위해, GICS 10개 섹터에서 각 1개 대표 종목을 균등하게 선정하였다. 이는 Moskowitz & Grinblatt(1999)의 산업군 기반 포트폴리오 전략과 Choueifaty & Coignard의 최대 다각화 이론에 기반한다. 선정 기준은 다음과 같다.

- 섹터 완전 다각화: GICS 10개 섹터(Industrials, Health Care, IT, Financials, Materials, Real Estate, Communication Services, Consumer Staples, Consumer Discretionary, Energy) 전체를 포함
- 데이터 품질: 섹터 내 후보 중 데이터 행 수가 가장 풍부한 종목을 우선 선정
- Disjoint Split: Train/Test 간 종목 중복을 원천 차단하여 정보 누출 방지

(4) 최종 종목 리스트: 위 절차를 통해 선정된 10개 Test 종목은 Table 4와 같다.

티커	종목명	섹터
MMM	3M Company	Industrials
ABT	Abbott Laboratories	Health Care
ACN	Accenture plc	Information Technology
AFL	Aflac Inc	Financials
APD	Air Products & Chemicals	Materials
ARE	Alexandria Real Estate	Real Estate
GOOGL	Alphabet Inc	Communication Services
MO	Altria Group	Consumer Staples
AMZN	Amazon.com Inc	Consumer Discretionary
APA	APA Corporation	Energy

Table 2. S&P 500에서 GICS 섹터별 균등 추출된 10개 Test 종목

이러한 종목 구성은 GICS 10개 섹터를 빠짐없이 포함하여 최대 수준의 섹터 다각화를 달성하였으며, Evans & Archer(1968)가 제시한 최적 분산투자 종목 수(10~15개)의 범위 내에 있다. 또한 Survivorship Bias 필터링을 통해 전체 실험 기간 동안 안정적으로 거래된 종목만을 포함하여 실험의 신뢰성을 확보하였다.

4.1.2 기타 데이터 구성 (Other Data Components)

선정된 10개 종목에 대해 다음의 데이터를 수집하였다.

- Yahoo Finance API (yfinance): 일별 주가(OHLCV - Open, High, Low, Close, Volume) 데이터
- Kenneth French Data Library (pandas-datareader): Fama & French(2015)의 5요인(Mkt-RF, SMB, HML, RMW, CMA) 일별 팩터 수익률

모델의 입력 특징은 두 가지 경로(Dual-Path)로 분리하여 구성하였다.

경로	특징	개수
Local (Price)	Open, High, Low, Close, Volume	5개
Global (Macro)	Mkt_RF, SMB, HML, RMW, CMA	5개
합계		10개

Table 3. Dual-Path 입력 특징 구성

이러한 Dual-Path 구조는 종목별 가격 신호(Local)와 시장 전체 거시경제 팩터(Global)의 신호 희석(Signal Dilution)을 방지하기 위해 설계되었다. 또한 기술적 지표(Momentum 1M/3M/6M/12M)는 TGNN의 예측 대상(Label)으로 활용되었다.

4.2 데이터 전처리 (Data Preprocessing)

데이터 품질을 보장하기 위해 다음의 전처리 절차를 수행하였다.

(1) 기술적 지표 생성 (Technical Indicator Engineering):

원시 OHLCV 데이터로부터 다음의 파생변수를 생성하여 TGNN의 예측 레이블(Label)로 활용하였다.

지표	산출 방법	목적
Momentum (1M, 3M, 6M, 12M)	각각 20, 60, 120, 252 거래일 수익률	다중 시간 스케일의 추세 포착 (예측 대상)
Volatility	20일 수익률 표준편차 $\times \sqrt{252}$ (연율화)	리스크 수준 정량화
RSI (14)	14일 상대강도지수	과매수/과매도 판단
MACD (12, 26, 9)	12일·26일 EMA 차이 및 9일 시그널	단기 모멘텀 전환 감지

Table 4. TGNN 입력 기술적 지표 및 산출 방법

(2) Fama-French 팩터 병합:

Kenneth French Data Library에서 일별 Fama-French 5-Factor 데이터를 다운로드하여, 날짜 기준 Left Join으로 주가 데이터와 병합하였다. 공휴일 등으로 인한 결측값은 Forward Fill로 보완하였다.

(3) 결측치 처리 (Missing Value Handling):

슬라이딩 윈도우 생성 시, 특정 종목의 데이터가 윈도우 길이보다 부족한 경우 Zero Padding을 적용하였다. 또한 각 윈도우의 마지막 날짜에 거래 데이터가 존재하지 않는 종목은 Active Mask를 통해 학습 시 제외하여, 비활성 종목이 Ranking Loss에 영향을 미치지 않도록 처리하였다.

(4) 정규화 (Normalization):

각 슬라이딩 윈도우 단위로 Robust Z-Score 정규화를 적용하였다. 구체적으로, 윈도우 내 전체 종목·시점의 평균(μ)과 표준편차(σ)를 계산하여 $x' = (x - \mu) / (\sigma + \epsilon)$ ($\epsilon = 10^{-8}$) 변환을 수행하였다. 이 방식은 가격(Local)과 매크로(Global) 특징을 상대적으로 스케일링하여 신호 간 균형을 유지한다.

(5) 그래프 구축 (Graph Construction):

종목 간 관계를 표현하기 위해 GICS 섹터 기반 인접 행렬(Adjacency Matrix)을 생성하였다. 동일 섹터에 속하는 종목 쌍에는 가중치 $w=1.0$, 이종 섹터 간에는 약한 연결($w=0.5$)을 부여하며, 자기 연결(Self-loop, $w=1.0$)을 포함하여 그래프가 완전 연결(Fully Connected)되도록 구성하였다. 이 그래프는 각 시점(Snapshot)별로 생성되어 TGNN의 공간적 관계 학습에 활용된다.

(6) 섹터 밸런싱 기반 데이터 분할 (Sector-Balanced Disjoint Split):

모델의 일반화 성능을 정확히 평가하기 위해, Train/Test 데이터셋을 Disjoint Split 전략으로 분리하였다. 이 전략은 두 단계로 구성된다.

1) Test Set 우선 선정: 각 섹터에서 데이터 품질이 충분한(≥ 600 거래일) 대표 종목을 균등하게 선정하여 Test Set(10개 종목)을 먼저 확정한다.

2) Train Set 배타적 선정: Test Set에 포함된 종목을 완전히 배제(Disjoint Condition)한 후, 나머지 종목 중 충분한 데이터($\geq 1,000$ 거래일)를 보유한 종목을 섹터당 균등하게 배분하여 Train Set을 구성한다. 이 접근법은 (a) 특정 산업군에 대한 편향을 방지하고, (b) Train/Test 간 종목 중복으로 인한 정보 누출(Data Leakage)을 원천적으로 차단하며, (c) 각 섹터의 시장 특성이 테스트 환경에 고르게 반영되도록 보장한다.

4.3 실험 환경 및 하이퍼파라미터 (Experimental Environment & Hyperparameters)

구성 요소	설정값
TGNN 히든 레이어	64
TGNN Attention Head	4
TGNN Dropout	0.1
DDPG Actor LR	$1e^{-4}$
DDPG Critic LR	$1e^{-3}$
할인계수 (γ)	0.99
Soft Update (τ)	0.001
배치 크기	64
Replay Buffer 크기	10,000
Softmax Temperature (τ)	3.0
Hybrid Alpha 범위	0.5 (고정)
Horizon Embedding Dim	8
Epoch 수	800
Optimizer	Adam

Table 5. 모델 하이퍼파라미터 설정

환경: Python 3.12 / PyTorch 2.1 / CUDA 12.9

하드웨어: NVIDIA GeForce RTX 2060 (VRAM 6GB)

운영체제: Windows 11

4.3.1 재현성 프로토콜 (Reproducibility Protocol)

본 연구는 학술적 신뢰성과 실험 결과의 완전한 재현성을 보장하기 위해 엄격한 재현성 프로토콜을 수립하고 준수하였다.

[1단계] 결정론적 실험 환경 구성

(1) Seed Fixing: Python, NumPy, PyTorch, CUDA 환경의 난수 시드(Seed)를 `42`로 고정하여 모든 실험의 초기화 상태를 통일하였다.

(2) Deterministic Algorithms: PyTorch 백엔드 설정에서 `torch.backends.cudnn.deterministic=True` 및 `torch.backends.cudnn.benchmark=False`를 적용하여, GPU 연산의 비결정적 요소(Non-deterministic behavior)를 제거하였다.

(3) Hardware Consistency: 하드웨어별 부동소수점 연산 차이를 최소화하기 위해 모든 실험은 단일 고정 환경(NVIDIA GeForce RTX 2060, Windows 11, CUDA 12.9)에서 수행되었다.

[2단계] 다중 시드 강건성 검증 (Multi-Seed Robustness Validation)

단일 시드 고정만으로는 실험 결과가 특정 초기화 상태에 의존하는 Lucky Seed 문제를 배제할 수 없다. 이에 본 연구는 5개의 독립적인 시드($S = \{0, 42, 123, 456, 789\}$)를 사용하여 모든 모델(TGNN, DDPG, Hybrid)과 전체 리밸런싱 주기(Monthly, Quarterly, Semiannual, Annual)에 대해 실험을 반복 수행하였다.

최종 보고 지표는 5회 실험의 평균(Mean)과 표준편차(Std)로 제시하여, 결과의 통계적 안정성을 검증하였다

$$\overline{m} \pm \sigma = \frac{1}{|S|} \sum_{s \in S} m_s \pm \sqrt{\frac{1}{|S|} \sum_{s \in S} (m_s - \overline{m})^2}$$

여기서 m_s 는 시드 S 에서의 성과 지표(CAGR, Sharpe Ratio 등)이다. 이 프로토콜은 단일 시드 결과의 과적합(Overfitting to a lucky seed) 위험을 차단하며, 제안 모델의 성과가 특정 초기화에 의존하지 않는 구조적 우위(Structural Advantage)임을 통계적으로 입증한다.

이러한 2단계 프로토콜을 통해, 본 연구의 실험 결과는 단순한 우연의 산물이 아닌, 검증 가능하고 재현 가능한 논리적 결과임을 보장한다..

4.4 평가 지표 (Evaluation Metrics)

제안된 모델의 성능은 세 가지 범주에서 평가하였다.

범주	지표	목적
예측 정확도 (Prediction Accuracy)	MSE, RMSE, R ²	TGNN 예측 및 임베딩 품질 평가
리스크 조정 성과 (Risk-adjusted Performance)	Sharpe Ratio, Sortino Ratio, DDPG 정책의 리스크-보상 균형 CVaR, Omega	가

Table 6. 성능 평가 지표 범주 및 목적

Sharpe Ratio와 Sortino Ratio는 다음과 같이 정의된다.

$$Sharpe = \frac{R_p - R_f}{\sigma_p}, Sortino = \frac{R_p - R_f}{\sigma_d}$$

CVaR(Conditional Value-at-Risk)은 손실 분포 하위 5%의 평균 손실로 측정하였다.

4.5 비교 모델 (Baseline Models)

제안된 하이브리드 AI DSS의 우수성을 검증하기 위해, 다음의 비교 대상을 설정하였다.

모델	설명	특성
Benchmark (Buy & Hold)	동일 비중 매입 후 보유 전략	패시브 전략 기준선
TGNN	그래프 기반 관계 예측 모델	시장 구조 반영 가능, 정책 최적화 미포함
DDPG	강화학습 기반 정책 최적화 모델	정책 학습 가능, 종목 간 관계 인식 불가
TGNN+DDPG (Proposed)	하이브리드 DSS 모델	관계·정책·양상블 최적화 통합 구조

Table 7. 비교 대상 모델(Baseline) 구성

각 모델은 Monthly, Quarterly, Semiannual, Annual의 4가지 리밸런싱 주기에서 독립적으로 평가하여, 주기별 성과 특성을 분석하였다.

4.6 검증 절차 및 강건성 평가 (Validation and Robustness Check)

모델의 일반화 성능과 신뢰성을 검증하기 위해, 시간적 순서를 엄격히 준수하는 데이터 분할을 수행하였다.

- 학습(Train): 2006-2020년 데이터 (약 3,700 거래일)
- 테스트(Test): 2021-2025년 데이터 (약 1,000 거래일)
- 종목 분리: Train/Test 간 Disjoint Split 적용 (섹터당 균등 배분, 종목 중복 없음)

Train/Test 간 종목이 완전히 분리(Disjoint)되어 있어, 특정 종목에 대한 과적합(Overfitting)이 아닌 시장 구조 자체를 학습했는지를 평가할 수 있다.

또한, 테스트 기간에는 코로나19 팬데믹 이후 회복기(2021), 러시아-우크라이나 전쟁(2022), 금리 인상기(2023) 등 다양한 시장 국면이 포함되어 있어, 모델의 강건성을 자연스럽게 검증할 수 있는 환경을 제공한다.

4.7 DSS 통합 및 피드백 구조 (Integration into DSS)

AI 엔진은 Flask 기반 API 서버에서 구동되며, Spring Boot 백엔드와 React 프론트엔드를 통해 DSS 인터페이스와 연동된다 (Park & Han, 2024).

모델 출력(추천 비중, 리스크 경고, 거래 제안 등)은 RESTful API를 통해 대시보드에 실시간 전송되고, 사용자 피드백은 데이터베이스에 저장되어 지속 학습(Continual Learning)에 활용된다. 또한 Explainable AI(XAI) 모듈을 통합하여 TGNN Multi-Head Temporal Self-Attention 가중치를 추출하고, Temporal Attention Map($T \times T$)과 Stock Attention Map($N \times T$)을 시각화함으로써 사용자가 AI의 의사결정 근거(reasoning path)를 직관적으로 이해할 수 있도록 하였다.

4.8 실험 설계 요약 (Summary of Experimental Design)

본 실험 설계는 다음의 세 가지 목표를 달성하도록 구성되었다.

- ① 관계 기반 예측 구조의 정확성 검증: TGNN의 시공간 관계 학습 능력을 평가.
- ② 정책 최적화 및 리스크 조정 성과 검증: DDPG 보상함수 내 리스크·비용 조정 효과 분석.
- ③ 실시간 DSS 통합 타당성 검증: Flask-Spring-React 환경에서 실시간 응답성과 피드백 효율성 평가.

5. 결과 및 논의 (Results and Discussion)

5.1 재무적 성과 비교 (Financial Performance Comparison)

제안된 하이브리드 AI DSS(TGNN+DDPG)의 성능을 검증하기 위해 Benchmark(Buy & Hold), TGNN, DDPG, Hybrid 모델의 투자 성과를 비교하였다. 실험은 Test 기간(2021-2025)의 데이터를 기반으로 수행되었으며, 5개의 독립 시드($S = \{0, 42, 123, 456, 789\}$)를 사용한 반복 실험의 평균(Mean) $\pm$ 표준편차(Std)로 결과를 보고한다.

Table 8은 각 모델의 리밸런싱 주기에 따른 주요 재무 성과 지표를 나타낸다.

Model	Period	CAGR (%)	Sharpe Ratio	MDD (%)	Total Return (%)
Benchmark	-	6.35 $\pm$ 0.00	0.25 $\pm$ 0.00	22.47 $\pm$ 0.00	27.35 $\pm$ 0.00
TGNN	Monthly	4.57 $\pm$ 1.43	0.13 $\pm$ 0.08	26.38 $\pm$ 7.29	19.29 $\pm$ 6.50
	Quarterly	3.54 $\pm$ 2.13	0.08 $\pm$ 0.10	24.29 $\pm$ 2.87	14.87 $\pm$ 9.36
	Semiannual	5.00 $\pm$ 3.21	0.16 $\pm$ 0.17	24.92 $\pm$ 1.61	21.63 $\pm$ 14.11
	Annual	8.38 $\pm$ 5.33	0.31 $\pm$ 0.25	25.52 $\pm$ 1.71	38.73 $\pm$ 27.01
DDPG	Monthly	-4.82 $\pm$ 5.06	-0.28 $\pm$ 0.20	35.68 $\pm$ 6.69	-16.59 $\pm$ 16.77
	Quarterly	-0.53 $\pm$ 4.87	-0.11 $\pm$ 0.21	32.69 $\pm$ 2.08	-0.95 $\pm$ 20.20
	Semiannual	-6.90 $\pm$ 4.62	-0.35 $\pm$ 0.18	35.35 $\pm$ 4.34	-23.61 $\pm$ 15.45
	Annual	-2.62 $\pm$ 3.68	-0.19 $\pm$ 0.15	37.58 $\pm$ 4.30	-9.31 $\pm$ 13.86
Hybrid (Proposed)	Monthly	5.50 $\pm$ 4.56	0.18 $\pm$ 0.22	27.10 $\pm$ 5.90	24.46 $\pm$ 20.05
	Quarterly	9.09 $\pm$ 2.86	0.34 $\pm$ 0.12	25.27 $\pm$ 4.13	41.22 $\pm$ 14.76
	Semiannual	2.96 $\pm$ 7.12	0.08 $\pm$ 0.32	26.02 $\pm$ 6.07	14.50 $\pm$ 27.90
	Annual	5.95 $\pm$ 6.76	0.22 $\pm$ 0.34	24.65 $\pm$ 3.24	27.84 $\pm$ 31.27

Table 8. Comprehensive Performance Analysis by Rebalancing Period (Test Period: 2021-2025)




Figure 2. CAGR by Rebalancing Frequency (5-Seed Mean $\pm$ Std). Error bars indicate standard deviation across seeds

실험 결과, Hybrid (Quarterly) 전략이 CAGR $9.09 \pm 2.86\%$, Sharpe Ratio 0.34 ± 0.12 로 Benchmark(CAGR 6.35%)를 가장 안정적으로 초과하는 성과를 기록하였다. 표준편차(2.86%)가 평균(9.09%)보다 현저히 작아, 이 결과가 특정 시드에 의존하지 않는 구조적 우위임을 확인할 수 있다.

DDPG 단독 모델은 모든 리밸런싱 주기에서 음수 CAGR($-0.53\% \sim -6.90\%$)을 기록하였다. 이는 DDPG Critic의 Q-value 과추정(Q-value Overestimation) 문제로 인해 강화학습 정책이 불안정하게 수렴한 결과로 해석된다. 반면, Hybrid (Quarterly)는 TGNN의 관계 예측 신호(CAGR 기여)가 DDPG의 불안정한 정책을 보완하여 벤치마크 초과 수익을 달성하였다. 이는 TGNN과 DDPG의 상호보완적 앙상블 구조가 효과적임을 입증한다.

TGNN 단독 모델은 Quarterly(3.54%)와 Monthly(4.57%) 주기에서 Benchmark를 하회한 반면, Hybrid (Quarterly)는 동일 주기에서 9.09%를 달성하여 앙상블을 통한 +5.55%p의 성과 개선을 보였다.

5.2 모델 강건성 분석 (Robustness and Consistency)




Figure 3. Risk-Return Profile across All Strategies (5-Seed Mean $\pm$ Std). Upper-left region indicates favorable risk-adjusted returns.

Figure 3의 리스크-수익 산점도에서 Hybrid 및 TGNN 전략들은 Benchmark 근방의 좌상단(저리스크-고수익)에 분포하는 반면, DDPG 전략들은 우하단(고리스크-저수익)에 집중되어 있다. 이는 Hybrid 앙상블이 DDPG의 리스크를 TGNN의 구조 인식 신호로 효과적으로 완화함을 시각적으로 확인시켜 준다.

Table 9는 리밸런싱 주기를 가로질러 각 모델의 평균 성과 및 시드 간 분산을 요약한다.

Model	Avg CAGR (%)	Avg CAGR Std	Avg Sharpe	Avg MDD (%)	Consistency
Benchmark	6.35	0.00	0.25	22.47	기준선
Hybrid	5.88	5.33	0.30	25.76	Quarterly 집중 시 우위
TGNN	5.37	3.07	0.17	25.28	Benchmark 미달 다수
DDPG	-3.72	4.76	-0.23	35.33	전 주기 음수 CAGR

Table 9. Cross-Frequency Average Performance Summary (5-Seed Mean)

전체 리밸런싱 주기를 평균하면 Hybrid의 성과 우위는 제한적이나, Quarterly 주기에 한정할 경우 Benchmark 대비 +2.74%p의 안정적 초과 수익이 관찰된다. 이는 분기(Quarterly) 단위 리밸런싱이 시장 신호 품질과 거래 비용 간 최적 균형점임을 시사한다.




Figure 4. Hybrid vs. TGNN CAGR by Rebalancing Frequency (5-Seed Mean $\pm$ Std). Hybrid outperforms TGNN by +5.55%p at Quarterly frequency.

5.3 DSS 통합 및 설명가능성 (System Integration and Explainability)

제안된 AI DSS는 Flask-Spring-React 통합 아키텍처를 기반으로 구현되었으며, 모델 출력(리밸런싱 비중, 리스크 경고, 거래 제안 등)은 REST API를 통해 대시보드에 실시간 반영된다.

DSS의 핵심은 사용자가 AI의 의사결정 과정을 이해할 수 있도록 설명가능성(Explainable AI, XAI)을 제

공하는 것이다. 본 연구에서는 TGNN의 Multi-Head Temporal Self-Attention 가중치를 추출하여 두 가지 시각화를 제공한다.

Temporal Attention Map (Figure 5a): 전체 종목에 대해 평균된 $T \times T$ Attention 행렬로, 모델이 포트폴리오 비중을 결정할 때 룩백 기간(Lookback Period) 내 어느 시점에 집중하는지를 보여준다. 최종 시점(Query)이 최근 시점(Key)에 높은 가중치를 부여하는 패턴은 TGNN이 단기 모멘텀 신호를 우선적으로 활용함을 시사한다.

Stock Attention Map (Figure 5b): 최종 쿼리 시점에서 각 종목(N)이 룩백 기간의 어느 시점에 주목하는지를 나타내는 $N \times T$ 행렬이다. 섹터별 종목 간 Attention 집중 시점의 차이를 통해, TGNN이 IT·금융 섹터와 에너지·소재 섹터가 서로 다른 시장 국면에 민감하게 반응함을 학습하였음을 확인할 수 있다.





Figure 5. TGNN Attention Visualization (Hybrid Quarterly, Test Period). (a) Temporal T×T attention averaged over stocks. (b) Stock-level N×T attention at the final prediction step.

5.4 고찰 (Discussion)

본 연구의 결과를 종합하면, 제안된 하이브리드 AI DSS는 다음과 같은 특성을 보였다.

- (1) 분기(Quarterly) 리밸런싱에서의 일관된 초과 수익: Hybrid (Quarterly)는 5-seed 평균 CAGR 9.09% $\pm$ 2.86%로, Benchmark(6.35%) 대비 +2.74%p의 안정적 초과 수익을 달성하였다. 표준편차가 평균의 31% 수준으로, 결과의 강건성이 확인된다.
- (2) TGNN의 DDPG 불안정성 보완: DDPG 단독은 전 주기 음수 CAGR을 기록한 반면, Hybrid (Quarterly)는 TGNN의 관계 예측 신호를 통해 이를 보완하여 양수 초과 수익을 달성하였다. 이는 두 모듈의 상호보완성을 실증한다.
- (3) 안정적인 리스크 프로파일: DDPG 단독(MDD 평균 35.33%)에 비해 Hybrid (Quarterly, MDD 25.27%)가 현저히 낮은 최대 낙폭을 기록하여 리스크 관리 효과를 확인하였다.
- (4) 다중 시드 재현성 확보: 5-seed 반복 실험을 통해 Hybrid (Quarterly)의 성과가 특정 초기화에 의존하지 않는 구조적 우위임을 통계적으로 입증하였다.

핵심 발견: 제안된 Hybrid 모델은 분기(Quarterly) 리밸런싱 주기에서 Benchmark를 +2.74%p 초과하는 안정적 성과를 기록하였으며, 이는 5-seed 반복 실험에서 일관되게 재현되었다. TGNN과 DDPG의 고정 알파($\alpha = 0.5$) 앙상블은 DDPG 단독 대비 리스크를 효과적으로 통제하면서 TGNN의 관계 예측 능력을 결합하는 상호보완적 시너지를 창출하였다.

결론적으로, 제안된 프레임워크는 실제 금융 시장의 복잡성을 효과적으로 다루며, 일관성 있는 (Consistent) 동시에 강건한(Robust) 지능형 의사결정지원시스템의 실현 가능성을 입증하였다.

6. 결론 및 향후 연구 (Conclusion and Future Work)

6.1 연구 요약 (Summary of Findings)

본 연구는 관계 학습(Relational Learning)과 정책 최적화(Policy Optimization)를 통합한 하이브리드 인공지능 기반 의사결정지원시스템(AI-based Decision Support System, AI-DSS)을 제안하였다.

제안된 시스템은 Temporal Graph Neural Network (TGNN)을 이용해 시장 내 종목 간 동적 상관구조를 학습하고, Deep Deterministic Policy Gradient (DDPG)를 통해 리스크와 수익 간의 균형을 강화학습 기반으로 최적화하였다. 두 모듈은 고정 알파($\alpha = 0.5$) 균등 앙상블로 통합되며, 특히 본 연구는 AI 모델의 결과가 우연이 아님을 입증하기 위해 5개 시드($S = \{0, 42, 123, 456, 789\}$)를 사용한 다중 시드 재현성 프로토콜(Multi-Seed Reproducibility Protocol)을 적용하였다.

5-seed 반복 실험 결과, 제안된 Hybrid (Quarterly) 모델은 CAGR $9.09 \pm 2.86\%$ 로 Benchmark(6.35%) 대비 +2.74%p의 안정적 초과 수익을 달성하였다. 이는 5회 반복 실험에서 일관되게 재현되어, 결과의 구조적 우위를 통계적으로 확인하였다. 또한 DDPG 단독 대비 MDD가 약 10%p 낮아 리스크 통제 효과도 입증하였다. 아울러 Flask-Spring-React 통합 아키텍처를 통해 AI 엔진이 실시간으로 DSS 환경에서 작동함을 검증하였다.

이러한 결과는 AI 모델링과 DSS 통합이 상호보완적으로 작용하여 AI DSS의 지능화(Intelligence), 자동화(Automation), 그리고 신뢰성(Trustworthiness)을 동시에 달성할 수 있음을 실증적으로 보여준다.

6.2 학문적 기여 (Academic Contributions)

본 연구의 학문적 기여는 다음 세 가지로 요약된다.

① 신뢰할 수 있는 AI DSS 방법론 확립: 기존 연구가 성능(Performance)에 집중한 반면, 본 연구는 결정론적 알고리즘(Deterministic Algorithm)을 도입하여 실험의 재현성(Reproducibility)을 보장함으로써, 금융 AI 연구가 나아가야 할 '신뢰 가능한 연구(Reproducible Research)'의 표준을 제시하였다.

② 시장 구조 인식형 의사결정 (Structure-Aware Decision Making): TGNN에서 학습된 관계 임베딩을 DSS 의사결정 프로세스에 반영하여, 비정형 금융 데이터의 구조적 패턴을 학습하고 활용하는 새로운 DSS 설계 방식을 제시하였다.

③ AI 모델링과 DSS 구조의 통합: TGNN-DDPG 결합을 통해 데이터 학습-정책 최적화-실행 효율화를 하나의 지능형 DSS 프레임워크로 통합하였다. 이는 Decision Support Systems 및 Knowledge-Based Systems에서 강조하는 AI 기반 자동화(AI-driven Decision Automation) 방향과 일치한다 (Al-Nassar et al., 2023; Zhang et al., 2024).

6.3 실무적 시사점 (Practical Implications)

본 연구의 AI DSS 프레임워크는 금융 분야를 중심으로 다음과 같은 실무적 활용 가능성을 가진다.

(1) 금융기관의 신뢰성 높은 리스크 관리: 설명가능성(XAI)과 결과의 일관성이 보장되므로, 금융 규제 준수가 필수적인 자산운용사의 실시간 위험관리 DSS 시스템에 즉시 적용 가능하다.

(2) AI 로보어드바이저 시스템 고도화: 기존 규칙 기반 로보어드바이저의 한계를 극복하고, 사용자별 맞춤형 정책 추천이 가능한 실시간 자동화 DSS 기술적 기반을 제공한다 (Gu et al., 2025).

(3) 금융 규제 및 윤리 대응: 설명가능성(XAI)을 내재화함으로써 MiFID II (2022), EU AI Act (2024) 등 AI 관련 규제의 투명성 요건(Explainability Requirement)을 충족할 수 있다.

6.4 한계 및 향후 연구 과제 (Limitations and Future Research)

본 연구는 의미 있는 결과를 도출했으나, 다음과 같은 한계와 향후 연구 방향이 존재한다.

① 데이터 범위의 제한: S&P 500 구성 종목을 중심으로 수행되었기 때문에, 향후 연구에서는 다자산 포트폴리오(ETF, 채권, 암호화폐)와 다중 시장(KOSPI, 유럽, 일본, 신흥국)으로 확장하여 일반화 가능성을 검증할 필요가 있다. 본 연구가 S&P 500이라는 특정 유니버스에 한정된 실험임을 인정하며 소형주나 신흥 시장으로의 일반화에는 추가 검증이 필요함을 명시한다.

② DDPG Critic 불안정성: 본 연구에서 DDPG 단독 모델은 전체 리밸런싱 주기에서 음수 CAGR을 기록하였다. 이는 DDPG Critic 네트워크의 Q-value 과추정(Q-value Overestimation) 문제가 주된 원인으로, 강화학습 학습 과정에서 Critic이 과적합되어 불안정한 포트폴리오 정책을 생성하는 것으로 분석된다. 향후 연구에서는 TD3(Twin Delayed DDPG, Fujimoto et al., 2018)의 이중 Critic 구조를 채택하거나 Soft Actor-Critic (SAC)을 적용하여 이를 완화할 수 있다.

③ 특정 리밸런싱 주기에서의 고분산: Hybrid Semiannual(std 7.12%)과 Annual(std 6.76%) 전략은 시드 간 표준편차가 평균에 근접하거나 초과하여 강건성이 제한된다. 이는 리밸런싱 이벤트 수가 적은 장기 주기에서 개별 리밸런싱 시점의 판단 오류가 전체 성과에 미치는 영향이 크기 때문이다. 본 연구의 핵심 결과는 분산이 상대적으로 낮은 Quarterly 주기에 한정하며, 장기 주기에 대한 일반화는 향후 연구에서 추가 검증이 필요하다.

④ 모델 복잡도 및 학습 효율성: TGNN-DDPG 구조는 계산비용이 높으므로, 향후에는 모델 경량화(Pruning, Distillation) 및 분산강화학습(Distributed RL) 기반의 효율적 학습 전략을 적용할 예정이다.

⑤ 멀티모달 DSS로의 확장: 현재 모델은 수치형 데이터 중심으로 설계되어 있으나, 향후 연구에서는 뉴스·SNS·애널리스트 리포트 등 자연어 데이터를 포함한 멀티모달 DSS(Multimodal DSS)로 확장할 계획이다.

6.5 결론적 논의 (Concluding Remarks)

본 연구는 AI 모델링과 의사결정지원시스템을 통합한 신뢰할 수 있는 지능형 DSS 프레임워크(Trustworthy Intelligent DSS Framework)의 새로운 방향을 제시하였다. AI가 단순한 예측 도구를 넘어 지능형 의사결정 엔진(Decision Intelligence Engine)으로 기능할 수 있음을 실증적으로 보였으며, 이는 DSS의 패러다임을 데이터 중심 예측 → 신뢰 가능한 의사결정지능(Trustworthy Decision Intelligence)으로 전환시키는 중요한 사례가 된다.

본 연구는 Decision Support Systems 저널이 강조하는 AI-driven Decision Making, Explainability, Reproducibility의 세 축을 모두 충족하며, 향후 AI DSS 연구의 학문적 기반과 실무적 응용 가능성을 동시에 확장시킬 것이다.

Reference

1. Al-Nassar, A., et al. (2023). Transformer-GNN hybrid for time-series learning. *Knowledge-Based Systems*, 263, 110396.
2. Bai, J., et al. (2023). Deep learning-based decision support framework for unstructured data analysis. *Information Sciences*, 639, 119042.
3. Chen, H., & Goetzmann, W. N. (2020). Rebalancing frequency and portfolio performance. *Journal of Financial Economics*, 138(3), 742-766.
4. Fama, E. F., & French, K. R. (2015). A five-factor asset pricing model. *Journal of Financial Economics*, 116(1), 1-22.
5. Fujimoto, S., et al. (2018). Addressing function approximation error in actor-critic methods. *ICML Proceedings*, 1587-1596.
6. Gong, Z., et al. (2025). Cross-market volatility forecasting with attention-based spatio-temporal GCN. *Economic Modelling*, 132, 106485.
7. Gu, X., et al. (2025). MTS: A Deep Reinforcement Learning Portfolio Management Framework with Time-Awareness. *Applied Intelligence*, 55(3), 1754-1771.
8. Hao, M., et al. (2025). Collaborative multi-agent reinforcement learning for portfolio management. *ACM Transactions on Intelligent Systems*, 18(2).
9. Kipf, T. N., & Welling, M. (2017). Semi-supervised classification with graph convolutional networks. *ICLR Proceedings*.
10. Lee, S., & Kim, J. (2023). AI-based Decision Intelligence in DSS. *Decision Support Systems*, 167, 114732.
11. Lin, R., et al. (2023). Deep Reinforcement Learning for Portfolio Optimization. *Neural Computing & Applications*, 35(9), 14528-14541.
12. Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *NeurIPS*, 30.
13. Park, J., & Han, S. (2024). Explainable AI for decision support in financial trading systems. *Decision Support Systems*, 176, 114865.
14. Wu, Z., et al. (2021). A comprehensive survey on graph neural networks. *IEEE Transactions on Knowledge and Data Engineering*, 33(4), 973-996.
15. Xiang, S., et al. (2022). Temporal and heterogeneous graph neural network for financial time series prediction. *ACM CIKM Proceedings*, 310-319.
16. Zhang, L., et al. (2024). Hybrid Reinforcement Learning-Based DSS for Investment Decision-Making. *Decision Support Systems*, 183, 115005.
17. Bai, Y., et al. (2024). Explainable graph-based financial DSS under uncertainty. *Expert Systems with Applications*, 241, 122858.
18. Liu, Yanjie, et al. "A Soft Actor-Critic Deep Reinforcement-Learning-Based Robot Navigation Method Using LiDAR." *Remote Sensing* 16.12 (2024): 2072.