

(가칭) Temporal Graph Neural Network와 강화학습을 통합한 하이브리드 인공지능 기반 포트폴리오 리밸런싱 의사결정지원 프레임워크

A Hybrid AI-Based Decision Support Framework Integrating Temporal Graph Neural Network and Reinforcement Learning for Portfolio Rebalancing

JoongHyun Park, Sehyun Kim, Junghyun Back, Hamin Kim, Kyungsik Lee, Hyun Lee

Abstract

디지털 전환과 인공지능(AI) 기술의 급속한 발전으로 의사결정 환경의 복잡성과 불확실성이 빠르게 증가하고 있다. 이에 따라 AI 기반 의사결정지원시스템(Decision Support Systems, DSS)의 중요성이 높아지고 있다. 본 연구는 금융 시장과 같이 동적이고 비정형적인 환경에서 지능적 의사결정을 지원하기 위한 신뢰할 수 있는(Trustworthy) 하이브리드 AI 기반 DSS 프레임워크를 제안한다.

제안된 시스템은 Temporal Graph Neural Network (TGNN), Deep Deterministic Policy Gradient (DDPG), 그리고 Dijkstra 최적화 알고리즘을 통합하여 포트폴리오 리밸런싱(Portfolio Rebalancing) 문제를 해결한다. 특히 본 연구는 단순한 성과 향상을 넘어, AI 의사결정의 재현성(Reproducibility)과 신뢰성(Reliability)을 보장하기 위한 결정론적(Deterministic) 알고리즘과 재현성 프로토콜을 도입하였다.

S&P 500 구성 종목을 대상으로 약 19년간(2006-2025)의 데이터를 활용한 실험 결과, 제안된 Hybrid 모델은 장기 리밸런싱 주기(Quarterly, Semiannual, Annual)에서 Benchmark를 일관되게 상회하였으며, 특히 Annual 주기에서 CAGR 9.28%를 달성하였다. DDPG(Annual)가 최고 CAGR 10.41%를 기록했지만 주기별 성과 편차가 커서 일부 구간에서 Benchmark를 하회한 반면, Hybrid 모델은 장기 투자 전략에 적합한 안정적 성과를 보여 학술적 가치를 입증하였다. 또한 Flask 기반 AI 서버와 Spring-React 사용자 인터페이스를 통합하여 실시간 DSS 환경을 구현하였으며, TGNN Attention 기반 설명가능성(Explainability) 기법을 통해 모델의 의사결정 과정을 투명하게 검증하였다.

본 연구는 예측 중심의 기존 DSS를 넘어, 관계 인식형(Structure-Aware)·재현 가능한(Reproducible)·설명 가능한(Explainable) 지능형 의사결정지원시스템의 새로운 표준을 제시한다.

Keywords

Decision Support Systems(DSS); Graph Neural Network (GNN); Reinforcement Learning(RL); Deep Deterministic Policy Gradient(DDPG); Temporal Graph Neural Network(TGNN); Reproducibility; Explainable Artificial Intelligence (XAI).

저널: Decision Support Systems (Elsevier, SCIE, IF $\approx$ 6.8)

논문 주제: Temporal Graph Neural Network와 강화학습을 통합한 하이브리드 인공지능 기반 포트폴리오 리밸런싱 의사결정지원 프레임워크

초점: AI 모델링 중심 + DSS 통합 응용

형식: IMRaD 구조 (서론-관련연구-방법론-실험-결과-결론)

# Temporal Graph Neural Network와 강화학습을 통합한 하이브리드 인공지능 기반 포트폴리오 리밸런싱 의사결정지원 프레임워크

## 1. 서론

AI 기반 디지털 전환(Digital Transformation)이 가속화되는 환경에서, 의사결정의 복잡성과 불확실성이 빠르게 증가하고 있다. 이러한 변화에 따라 인공지능(AI) 기반 의사결정지원시스템(Decision Support Systems, DSS)의 중요성이 한층 높아지고 있다.

특히 금융 시장은 데이터의 복잡성, 비정형성, 그리고 높은 변동성으로 인해 전통적인 통계 기반 의사결정 모형의 한계가 명확히 드러나고 있다(Park & Han, 2024; Chen & Goetzmann, 2020). 이에 따라 복합 데이터 구조를 처리할 수 있는 딥러닝(Deep Learning) 및 강화학습(Reinforcement Learning) 기반의 DSS 연구가 활발히 이루어지고 있으며, 최근에는 종목 간 상관관계나 시장 네트워크 구조를 학습할 수 있는 그래프 신경망(Graph Neural Network, GNN)과 정책 최적화를 수행하는 강화학습(Reinforcement Learning, RL)을 결합한 하이브리드 DSS 프레임워크가 새로운 패러다임으로 주목받고 있다 (Al-Nassar et al., 2023; Zhang et al., 2024).

### 1.1 연구 배경 및 필요성

기존의 금융 DSS는 대부분 회귀분석, ARIMA, 혹은 LSTM 기반의 단일 시계열 예측 모델에 의존해왔다. 이러한 접근법은 개별 종목의 수익률 예측에는 효과적이지만, 시장 구조적 상호작용, 다차원적 리스크 요인, 동적 정책 최적화를 반영하기 어렵다는 한계를 지닌다 (Wu et al., 2021).

최근 Decision Support Systems 저널은 AI 기반 DSS의 구조적 진화를 강조하고 있으며, 특히 비정형 네트워크 데이터 기반의 "관계형 DSS(Relational DSS)" 개념이 전통적인 규칙 기반 시스템의 한계를 극복할 새로운 접근으로 제시되고 있다. 또한 단순한 예측 성능뿐만 아니라, AI 모델의 결과를 신뢰할 수 있는지에 대한 "신뢰성(Trustworthiness)" 문제가 중요한 화두로 떠오르고 있다.

### 1.2 최근 연구 동향

AI DSS 관련 최신 연구는 크게 두 가지 방향으로 발전하고 있다.

첫째, AI 모델링 중심 DSS 연구에서는 머신러닝·딥러닝 모델을 DSS 구조에 통합하여 의사결정의 정확성과 적응성을 향상시키는 방향이 주목받고 있다. 예를 들어, Zhang et al. (2024)은 Transformer 기반 DSS를 통해 비정형 금융 텍스트 데이터를 통합하여 의사결정 품질을 높였으며, Lin et al. (2023)은 강화학습을 적용해 리스크 조정 수익률을 향상시키는 정책학습 기반 포트폴리오 DSS를 제안하였다.

둘째, AI DSS 응용 및 통합 연구에서는 AI 모듈을 DSS 환경 내에서 실시간으로 동작시키는 구조적 프레임워크 설계가 활발히 진행되고 있다. Park & Han (2024)은 Flask 기반 API 서버를 활용한 AI-DSS 통합 구조를 제안하여, 사용자 피드백 루프를 포함한 지속 학습(Continual Learning) 프로세스를 구현하였다.

그러나 이러한 연구들은 주로 모델의 수익률(Profitability)이나 예측 정확도(Accuracy) 향상에 집중하는 경향이 있으며, AI 모델이 일관된 결과를 산출하는지(Reproducibility), 다양한 환경에서도 신뢰할 수 있는지(Reliability)에 대한 검증은 상대적으로 부족한 실정이다.

### 1.3 연구 공백 및 문제 제기

이러한 발전에도 불구하고 다음과 같은 한계가 여전히 존재한다.

- (1) 대부분의 연구가 모델의 성능 극대화에 치중하여, 실험 결과의 재현성(Reproducibility)과 신뢰성 검증을 간과하였다.
- (2) 기존 DSS는 AI 모델을 예측 모듈로만 활용하여 의사결정의 상호작용 구조(예: 종목 간 관계)를 반영하지 못했다.

(3) 강화학습 기반 DSS 연구들은 거래비용이나 경로 제약 등 실행 단계의 제약조건(Operational Constraints)을 통합적으로 고려하지 않았다.

따라서, 관계 학습(Relationship Learning), 정책 학습(Policy Optimization)뿐만 아니라 신뢰할 수 있는 재현성(Reproducibility)을 갖춘 통합 AI DSS 프레임워크의 필요성이 제기된다.

#### 1.4 연구 목적 및 기여

본 연구는 위의 한계를 해결하기 위해, Temporal Graph Neural Network (TGNN), Deep Deterministic Policy Gradient (DDPG), 그리고 Dijkstra 최적화 알고리즘을 통합한 하이브리드 AI DSS를 제안한다.

이 시스템은 다음 세 단계로 구성된다.

- (1) TGNN을 통해 시장 내 관계 구조를 학습하고,
- (2) DDPG를 통해 포트폴리오 비중 조정 정책을 강화학습 기반으로 최적화하며,
- (3) Dijkstra 알고리즘을 이용해 거래비용을 최소화한다.

본 연구는 S&P 500 구성 종목 중 GICS 섹터별 대표 종목을 1개씩 추출하여 10개 종목으로 실험을 수행하였다. 종목 선정 시 Survivorship Bias를 방지하기 위해 실험 전체 기간(2006-2025) 동안 상장이 유지된 종목만을 대상으로 하였으며, 섹터 다각화를 통해 특정 산업군에 편중되지 않는 일반화 가능한 포트폴리오를 구성하였다.

이를 통해 본 연구는 다음과 같은 기여를 한다.

- ① AI 모델 통합형 DSS 설계: 예측-정책-비용 최적화의 세 단계를 AI 모듈로 연결하는 통합형 DSS 아키텍처를 제안한다.
- ② AI DSS의 실시간 자동화 구현: Flask-Spring-React 기반의 시스템 통합을 통해 사용자 피드백이 실시간으로 AI 정책 업데이트에 반영되는 구조를 구현한다.
- ③ 학문적·실무적 시사점 제시: 학문적으로는 AI DSS의 구조적 확장을 제시하고, 실무적으로는 금융 의사결정에서 설명가능(Explainable) 하고 자동화된 지능형 DSS(Automated Intelligent DSS)의 가능성을 입증한다.

## 2. 관련 연구 (Related Works)

### 2.1 AI 기반 의사결정지원시스템의 진화 (Evolution of AI-Based Decision Support Systems)

최근 DSS 분야는 단순한 규칙 기반(rule-based) 시스템에서 인공지능(AI) 기반의 지능형 의사결정지원(Intelligent Decision Support)으로 빠르게 발전하고 있다. Decision Support Systems 저널의 Lee and Kim (2023)은 AI 기반 의사결정엔진을 도입함으로써 전통적 분석형 DSS의 한계를 보완할 수 있음을 보였다. Applied Intelligence의 Gu et al. (2025)는 강화학습(RL) 엔진을 DSS 아키텍처에 내재화하여 시장 변화에 실시간 대응할 수 있는 AI-driven 의사결정엔진을 제시하였다. 또한 Information Sciences의 Bai et al. (2023)은 딥러닝을 활용한 의사결정지원 프레임워크를 검증하며, AI 모델이 비정형 데이터에서 의미 추론과 정책 추천을 수행할 수 있음을 입증하였다.

이처럼 최근 연구들은 AI 기술을 DSS의 핵심 요소로 간주하며, 예측 정확성뿐 아니라 설명가능성(Explainability) 및 적응성(Adaptivity)을 동시에 강조하는 방향으로 진화하고 있다 (Park & Han, 2024; Zhang et al., 2024). 그러나 대부분의 연구가 단일 AI 모델 중심 예측에 머물러 있으며, 다중 AI 모델 간 상호작용 또는 실험 결과의 재현성(Reproducibility)에 대한 체계적 검증은 아직 부족한 실정이다.

### 2.2 강화학습 기반 의사결정지원 (Decision Support with Reinforcement Learning)

강화학습(RL)은 비정형 환경에서 스스로 정책을 학습하는 능력으로 DSS 분야에 적극적으로 도입되고 있다. Neural Computing and Applications의 Lin et al. (2023)은 DDPG 모델을 적용한 DSS 프레임워크를 통해 비용-효율적인 포트폴리오 리밸런싱 정책을 학습하였으며, Knowledge-Based Systems의 Al-Nassar et al. (2023)은 Transformer 기반 정책 네트워크를 RL과 결합해 시계열 상관관계를 반영하였다.

최근 Liu et al. (2024)의 연구는 Soft Actor-Critic (SAC) 강화학습 알고리즘을 로봇 네비게이션에 적용하여 동적 장애물 환경에서의 의사결정을 효과적으로 해결하였다. 이 연구에서 제시된 SAC 기반 경로 계획 시스템은 continuous action space에서의 정책 최적화를 통해 실시간 환경 변화에 대응하는 의사결정을 수행한다. 특히 Liu et al.의 방법론에서 주목할 점은 전문가 궤적 기반 모방학습(Expert Trajectory-based Imitation Learning)과 우선순위 경험 재생(Prioritized Experience Replay) 기법을 결합하여 학습 효율성과 안전성을 동시에 향상시켰다는 점이다.

본 연구의 DSS 프레임워크는 Liu et al. (2024)의 SAC 알고리즘 구조를 금융 의사결정 영역에 적용하여 확장한다. 로봇 네비게이션에서의 상태-행동-보상 구조를 시장 상태-포트폴리오 조정-수익률/리스크 보상으로 변환하고, SAC의 actor-critic 네트워크 구조를 TGNN 임베딩과 결합함으로써 관계 인식형 정책 학습을 구현한다. 또한 Liu et al.의 RNN 기반 전이 추론 능력(Transfer Inference with RNN)에서 착안하여, 시장 변동성이 높은 환경에서도 안정적인 의사결정이 가능한 적응형 DSS를 설계한다.

Decision Support Systems의 Zhang et al. (2024)은 PPO와 TD3 알고리즘을 비교하여 AI 정책이 리스크 관리 측면에서도 효율적으로 작동함을 보였다.

이와 같이 RL 기반 DSS 연구들은 의사결정의 자동화 수준을 높였지만, 대부분이 단일 정책 학습에 국한되어 예측 모듈과 정책 모듈을 투자 주기에 따라 동적으로 결합하는 앙상블 메커니즘은 부재하였다. 본 연구는 이러한 한계를 극복하기 위해 TGNN 기반 관계 학습과 DDPG 기반 정책 최적화를 Horizon-Aware Dynamic Alpha로 통합하는 앙상블 기법을 제안한다.

### 2.3 그래프 신경망 기반 관계 학습 (Relational Learning with Graph Neural Networks)

복잡한 금융 데이터 환경에서 관계적 정보를 모델링하기 위해 그래프 신경망(Graph Neural Networks, GNN)이 핵심 도구로 자리잡고 있다. IEEE Transactions on Knowledge and Data Engineering의 Wu et al. (2021)은 GNN이 비유클리드 데이터의 관계 패턴을 정확히 학습할 수 있음을 보였고, ACM CIKM의 Xiang et al. (2022)은 Temporal GNN을 적용해 시장 동조화 효과를 모델링하였다. 또한 Economic

Modelling의 Gong et al. (2025)은 Attention 기반 시공간 그래프 컨볼루션 모델을 활용하여 시장 간 변동성 예측 정확도를 향상시켰다.

그러나 기존 연구들은 GNN 출력을 단순한 예측 모듈로만 활용하며, 이를 의사결정 정책 최적화 단계(RL 또는 DSS 모듈)로 직접 연결한 사례는 거의 없다. 본 연구는 TGNN으로부터 얻은 관계 임베딩을 강화학습의 상태공간(State Space) 입력으로 활용하여, 관계 인지형(Relationship-Aware) DSS의 새로운 구조를 제시한다.

2.4 AI DSS 시스템 통합 연구(System Integration of AI Modules)

AI 기반 모델을 DSS 환경에 실시간으로 통합하는 연구는 아직 초기 단계에 머물러 있다. Decision Support Systems의 Park and Han (2024)은 Flask API와 React UI를 활용한 AI DSS 시스템 아키텍처를 설계하고, 사용자 피드백 루프를 통해 모델 성능을 지속적으로 갱신할 수 있음을 보였다. 또한 Applied Intelligence의 Gu et al. (2025)은 강화학습 모듈을 DSS의 실행 엔진으로 통합하여 정책 결정과 결과 분석이 자동화되는 구조를 제시하였다.

이러한 통합형 AI DSS는 데이터 수집-분석-정책결정-피드백-재학습의 순환형 프레임워크를 실현함으로써, 기존 단방향 의사결정 시스템의 한계를 극복한다.

2.5 요약 및 연구 차별성

| 비교 항목       | 기존 연구         | 본 연구의 차별성                     |
|-------------|---------------|-------------------------------|
| AI DSS 구조   | 단일 모델 예측형 DSS | TGNN-DDPG 통합형 하이브리드 DSS       |
| 정책 학습       | 수익률 중심        | 리스크 조정 보상 + 동적 앙상블 정책 최적화     |
| 관계 학습       | 예측 모듈로 한정     | 관계 임베딩을 정책 학습 입력으로 활용         |
| 시스템 통합      | 오프라인 모델 중심    | 실시간 API 연동형 DSS 통합 구조         |
| 해석 가능성(XAI) | 일부 후처리 분석     | SHAP + Attention 기반 실시간 설명 제공 |

요약하면, 본 연구는 AI 모델링과 DSS 시스템 통합을 유기적으로 결합하여, 예측-정책-비용 최적화가 순환적으로 작동하는 지능형 AI DSS 프레임워크를 제안한다.

### 3. 제안 모델 (Proposed Hybrid AI Model)

#### 3.1 개요 (Overview)


본 연구는 관계 학습(Relational Learning)과 정책 최적화(Policy Optimization)를 통합한 하이브리드 인공지능 기반 의사결정지원시스템(AI-based Decision Support System, AI-DSS)을 제안한다.

제안된 프레임워크는 Temporal Graph Neural Network (TGNN)와 Deep Deterministic Policy Gradient (DDPG) 두 모듈을 결합한 하이브리드 에이전트(Hybrid Agent) 구조를 기반으로 하며, 예측-결정-실행의 연속 피드백 루프를 형성한다. AI DSS의 전체 구조는 그림 1과 같이 데이터 수집-관계 학습-정책 최적화-비용 최소화-의사결정 피드백의 순환 구조로 구성된다.

이 프레임워크는 단순한 데이터 분석을 넘어 시장의 구조적 상호작용을 학습하고, 강화학습 기반 의사결정을 자동화하며, DSS 내 실시간 정책 피드백을 가능하게 한다. 특히 본 연구에서는 기존의 단일 통합 모델 구조를 개선하여, 독립적인 DDPG와 TGNN 인스턴스를 조합(Composition)하고 리밸런싱 주기에 따라 가중치를 동적으로 조절하는 Horizon-Aware Ensemble 메커니즘을 도입하였다.

#### 3.1.1 자산 무관형 아키텍처 (Asset-Agnostic Architecture)

본 연구의 핵심 기여 중 하나는 자산 무관형(Asset-Agnostic) 구조의 도입이다. 기존 포트폴리오 모델들이 고정된 수의 주식(N)에 대해 학습하여 유니버스 변경 시 재학습이 필요한 것과 달리, 제안된 모델은 가변적인 시장 상황(Variable N)에 유연하게 대응한다. 이는 Shared Encoder(공유 가중치)와 Deep Sets (집합 연산) 기술을 적용하여 달성된다.



#### 3.2 관계 학습 모듈: Temporal Graph Neural Network (TGNN)

TGNN은 Kipf & Welling (2017)이 제안한 Graph Convolutional Network(GCN)를 시간축으로 확장하여, 시장 내 주식 간 동적 상관구조를 학습한다. 시점  $t$ 에서의 그래프  $G_t$ 는 노드  $V$ (주식), 엣지  $E_t$ (관계)로 구성된다. 엣지 가중치는 피어슨 상관계수와 산업 유사도를 결합해 산출된다.

### 3.2.1 Context-Aware Dual-Path Encoder

본 연구에서는 가격 데이터와 거시경제 지표를 분리 처리하는 Dual-Path Encoder 구조를 채택하였다.

(1) Price Encoder: GRU(Gated Recurrent Unit)를 사용하여 종목별 가격 시계열([B, N, T, 5])을 학습

(2) Macro Encoder: 1D-CNN을 사용하여 Fama-French 5-Factor 등 거시경제 지표([B, N, T, 5])를 학습

두 경로의 출력은 Concatenation 후 GCN 레이어로 전달되어 공간적 관계를 학습한다. 그래프 합성곱 연산은 다음과 같이 정의된다.

$$H^{(l+1)} = \sigma(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^{(l)} W^{(l)})$$

여기서  $\tilde{A} = A + I$ 는 자기 연결이 추가된 인접행렬,  $\tilde{D}$ 는 차수행렬이다. 본 모델은 안정적 학습을 위해 잔차 연결(Residual Connection)과 Layer Normalization을 적용하였다.

### 3.2.2 Multi-Head Prediction & Loss Function

4가지 기간(1개월, 3개월, 6개월, 12개월)의 가격 모멘텀을 동시에 예측하는 멀티 태스크(Multi-Task) 구조를 채택하였다. 손실 함수는 절대 오차와 상대 순위를 모두 고려한 복합 손실을 사용한다.

$$L = \alpha \cdot L_{MSE} + \beta \cdot L_{Ranking}$$

여기서  $\alpha = 0.7$ ,  $\beta = 0.3$ 이며, Ranking Loss는 A가 B보다 수익률이 높으면, 예측값도  $A > B$ 여야 한다는 쌍별 순위를 수식화한다.

### 3.3 정책 학습 모듈: Deep Deterministic Policy Gradient (DDPG)

정책 학습 모듈은 자산 무관형(Asset-Agnostic) 강화학습을 수행한다.

(1) SharedFactorEncoder: 개별 종목의 시계열 특징을 처리하는 공유 인코더(Shared MLP)를 사용하여, 종목 수(N)에 관계없이 동일한 파라미터로 특징을 추출한다.

(2) ScoreHead & Portfolio Softmax: 추출된 특징으로부터 점수를 계산하고, Temperature-scaled Softmax를 통해 합이 1인 비중을 생성한다. Temperature 파라미터( $\tau = 3.0$ )는 포트폴리오 분산도를 조절하며, 높은 값은 균등 배분에 가까운 비중을, 낮은 값은 집중 투자를 유도한다.

$$W_i = \frac{\exp(s_i/\tau)}{\sum_{j=1}^N \exp(s_j/\tau)}$$

(3) Deep Sets Critic: Critic 네트워크는 상태-행동 쌍(State-Action Pair)을 평가할 때 Deep Sets 구조를 사용하여, 포트폴리오 크기가 변해도 재학습 없이 Q-value를 추정한다.

$$Q(S, A) = \rho \left( \sum_{i=1}^N \phi(s_i, a_i) \right)$$

여기서  $\phi$ 는 로컬 인코더,  $\rho$ 는 글로벌 Q-Head이다.

### 3.4 Hybrid Alpha & System Integration

세 모듈은 Python 기반 Flask API 서버에서 AI 엔진으로 작동하며, Spring Boot 백엔드와 React 프론트

엔드를 통해 DSS 대시보드로 통합된다.

3.4.1 Horizon-Aware Dynamic Alpha

본 연구는 TGNN(예측 기반)과 DDPG(정책 기반)의 기여도를 동적으로 조절하기 위해 Horizon Embedding을 도입하였다. 리밸런싱 주기(Horizon) 정보(0: Monthly, 1: Quarterly, 2: Semiannual, 3: Annual)를 임베딩 벡터로 변환하여 앙상블 네트워크에 주입한다.

최종 포트폴리오 비중  $W_{final}$ 은 다음과 같이 계산된다.

$$W_{final} = \alpha \cdot W_{TGNN} + (1 - \alpha) \cdot W_{DDPG}$$

여기서  $\alpha$ 는 Global Pooling Network를 통해 산출된 동적 가중치이며, Mode Collapse 방지를 위해  $\alpha \in [0.2, 0.8]$  범위로 클램핑(Clamping)된다. 이를 통해 한 모델이 100% 비중을 가져가는 것을 방지하고, TGNN(예측)과 DDPG(최적화)의 장점을 항상 혼합하여 과적합을 방지한다.

3.5 제안 모델의 구조 요약

| 모듈       | 주요 역할  | 핵심 기술                           | DSS 기여도            |
|----------|--------|---------------------------------|--------------------|
| TGNN     | 관계 학습  | Multi-Head GCN + Temporal Attn  | 시장 구조 및 추세 동시 학습   |
| DDPG     | 정책 최적화 | Asset-Agnostic (Shared Weights) | 가변 유니버스 대응 및 최적화   |
| Ensemble | 통합 제어  | Horizon-Aware Dynamic Alpha     | 투자 주기에 따른 최적 모델 조합 |
| 통합 시스템   | DSS 운영 | Flask-Spring-React 구조           | 실시간 피드백 & XAI      |



4. 실험 설계 (Experimental Design)

4.1 데이터셋 구성 (Dataset Description)

본 연구에서는 2006년 1월부터 2025년까지의 글로벌 주식 시장 데이터를 활용하였다. 학습 기간(Train)은 2006-2020년, 테스트 기간(Test)은 2021-2025년으로 설정하였다. 포트폴리오 구성 종목은 S&P 500 지수의 구성 종목 중 GICS(Global Industry Classification Standard) 섹터 다각화 원칙에 따라 체계적으로 선정하였다.

4.1.1 종목 선정 방법론 (Stock Selection Methodology)

포트폴리오 종목 선정은 다음의 절차를 통해 수행되었다.

(1) S&P 500 종목 자동 수집: Wikipedia의 S&P 500 구성 종목 리스트를 자동 크롤링하여 전체 후보군을 확보하였다. 각 종목의 GICS 섹터 및 세부 산업 정보는 크롤링 데이터와 yfinance API를 통해 교차 검증하였다.

(2) Survivorship Bias 방지 필터링: 실험의 타당성을 확보하기 위해, 전체 실험 기간(2006-2025) 동안 상장이 유지된 종목만을 대상으로 하였다. 구체적으로, Train 기간(2006-2020)에 최소 1,000 거래일, Test 기간(2021-2025)에 최소 600 거래일의 데이터를 보유한 종목만 후보로 선정하였다.

(3) 섹터별 균등 추출: 포트폴리오의 위험 분산 효과를 극대화하기 위해, GICS 10개 섹터에서 각 1개 대표 종목을 균등하게 선정하였다. 이는 Moskowitz & Grinblatt(1999)의 산업군 기반 포트폴리오 전략과 Choueifaty & Coignard의 최대 다각화 이론에 기반한다. 선정 기준은 다음과 같다.

- 섹터 완전 다각화: GICS 10개 섹터(Industrials, Health Care, IT, Financials, Materials, Real Estate, Communication Services, Consumer Staples, Consumer Discretionary, Energy) 전체를 포함
- 데이터 품질: 섹터 내 후보 중 데이터 행 수가 가장 풍부한 종목을 우선 선정
- Disjoint Split: Train/Test 간 종목 중복을 원천 차단하여 정보 누출 방지

(4) 최종 종목 리스트: 위 절차를 통해 선정된 10개 Test 종목은 Table 4와 같다.

| 티커    | 종목명                      | 섹터                     |
|-------|--------------------------|------------------------|
| MMM   | 3M Company               | Industrials            |
| ABT   | Abbott Laboratories      | Health Care            |
| ACN   | Accenture plc            | Information Technology |
| AFL   | Aflac Inc                | Financials             |
| APD   | Air Products & Chemicals | Materials              |
| ARE   | Alexandria Real Estate   | Real Estate            |
| GOOGL | Alphabet Inc             | Communication Services |
| MO    | Altria Group             | Consumer Staples       |
| AMZN  | Amazon.com Inc           | Consumer Discretionary |
| APA   | APA Corporation          | Energy                 |

Table 4. S&P 500에서 GICS 섹터별 균등 추출된 10개 Test 종목

이러한 종목 구성은 GICS 10개 섹터를 빠짐없이 포함하여 최대 수준의 섹터 다각화를 달성하였으며, Evans & Archer(1968)가 제시한 최적 분산투자 종목 수(10~15개)의 범위 내에 있다. 또한 Survivorship Bias 필터링을 통해 전체 실험 기간 동안 안정적으로 거래된 종목만을 포함하여 실험의 신뢰성을 확보하였다.

4.1.2 기타 데이터 구성 (Other Data Components)

선정된 10개 종목에 대해 다음의 데이터를 수집하였다.

- Yahoo Finance API (yfinance): 일별 주가(OHLCV - Open, High, Low, Close, Volume) 데이터
- Kenneth French Data Library (pandas-datareader): Fama & French(2015)의 5요인(Mkt-RF, SMB, HML, RMW, CMA) 일별 팩터 수익률

모델의 입력 특징은 두 가지 경로(Dual-Path)로 분리하여 구성하였다.

| 경로             | 특징                             | 개수  |
|----------------|--------------------------------|-----|
| Local (Price)  | Open, High, Low, Close, Volume | 5개  |
| Global (Macro) | Mkt_RF, SMB, HML, RMW, CMA     | 5개  |
| 합계             |                                | 10개 |

이러한 Dual-Path 구조는 종목별 가격 신호(Local)와 시장 전체 거시경제 팩터(Global)의 신호 희석(Signal Dilution)을 방지하기 위해 설계되었다. 또한 기술적 지표(Momentum 1M/3M/6M/12M)는 TGNN의 예측 대상(Label)으로 활용되었다.

4.2 데이터 전처리 (Data Preprocessing)

데이터 품질을 보장하기 위해 다음의 전처리 절차를 수행하였다.

(1) 기술적 지표 생성 (Technical Indicator Engineering):

원시 OHLCV 데이터로부터 다음의 파생변수를 생성하여 TGNN의 예측 레이블(Label)로 활용하였다.

| 지표                         | 산출 방법                                  | 목적                       |
|----------------------------|----------------------------------------|--------------------------|
| Momentum (1M, 3M, 6M, 12M) | 각각 20, 60, 120, 252 거래일 수익률            | 다중 시간 스케일의 추세 포착 (예측 대상) |
| Volatility                 | 20일 수익률 표준편차 $\times \sqrt{252}$ (연율화) | 리스크 수준 정량화               |
| RSI (14)                   | 14일 상대강도지수                             | 과매수/과매도 판단               |
| MACD (12, 26, 9)           | 12일·26일 EMA 차이 및 9일 시그널                | 단기 모멘텀 전환 감지             |

(2) Fama-French 팩터 병합:

Kenneth French Data Library에서 일별 Fama-French 5-Factor 데이터를 다운로드하여, 날짜 기준 Left Join으로 주가 데이터와 병합하였다. 공휴일 등으로 인한 결측값은 Forward Fill로 보완하였다.

(3) 결측치 처리 (Missing Value Handling):

슬라이딩 윈도우 생성 시, 특정 종목의 데이터가 윈도우 길이보다 부족한 경우 Zero Padding을 적용하였다. 또한 각 윈도우의 마지막 날짜에 거래 데이터가 존재하지 않는 종목은 Active Mask를 통해 학습 시 제외하여, 비활성 종목이 Ranking Loss에 영향을 미치지 않도록 처리하였다.

(4) 정규화 (Normalization):

각 슬라이딩 윈도우 단위로 Robust Z-Score 정규화를 적용하였다. 구체적으로, 윈도우 내 전체 종목·시점의 평균( $\mu$ )과 표준편차( $\sigma$ )를 계산하여  $x' = (x - \mu) / (\sigma + \epsilon)$  ( $\epsilon = 10^{-8}$ ) 변환을 수행하였다. 이 방식은 가격(Local)과 매크로(Global) 특징을 상대적으로 스케일링하여 신호 간 균형을 유지한다.

(5) 그래프 구축 (Graph Construction):

종목 간 관계를 표현하기 위해 GICS 섹터 기반 인접 행렬(Adjacency Matrix)을 생성하였다. 동일 섹터에 속하는 종목 쌍에는 가중치  $w=1.0$ , 이종 섹터 간에는 약한 연결( $w=0.5$ )을 부여하며, 자기 연결(Self-loop,  $w=1.0$ )을 포함하여 그래프가 완전 연결(Fully Connected)되도록 구성하였다. 이 그래프는 각 시점(Snapshot)별로 생성되어 TGNN의 공간적 관계 학습에 활용된다.

#### (6) 섹터 밸런싱 기반 데이터 분할 (Sector-Balanced Disjoint Split):

모델의 일반화 성능을 정확히 평가하기 위해, Train/Test 데이터셋을 Disjoint Split 전략으로 분리하였다. 이 전략은 두 단계로 구성된다.

1) Test Set 우선 선정: 각 섹터에서 데이터 품질이 충분한( $\geq 600$  거래일) 대표 종목을 균등하게 선정하여 Test Set(10개 종목)을 먼저 확정한다.

2) Train Set 배타적 선정: Test Set에 포함된 종목을 완전히 배제(Disjoint Condition)한 후, 나머지 종목 중 충분한 데이터( $\geq 1,000$  거래일)를 보유한 종목을 섹터당 균등하게 배분하여 Train Set을 구성한다. 이 접근법은 (a) 특정 산업군에 대한 편향을 방지하고, (b) Train/Test 간 종목 중복으로 인한 정보 누출(Data Leakage)을 원천적으로 차단하며, (c) 각 섹터의 시장 특성이 테스트 환경에 고르게 반영되도록 보장한다.

#### 4.3 실험 환경 및 하이퍼파라미터 (Experimental Environment & Hyperparameters)

| 구성 요소                          | 설정값        |
|--------------------------------|------------|
| TGNN 히든 레이어                    | 64         |
| TGNN Attention Head            | 4          |
| TGNN Dropout                   | 0.1        |
| DDPG Actor LR                  | $1e^{-4}$  |
| DDPG Critic LR                 | $1e^{-3}$  |
| 할인계수 ( $\gamma$ )              | 0.99       |
| Soft Update ( $\tau$ )         | 0.001      |
| 배치크기                           | 64         |
| Replay Buffer 크기               | 10,000     |
| Softmax Temperature ( $\tau$ ) | 3.0        |
| Hybrid Alpha 범위                | [0.1, 0.9] |
| Horizon Embedding Dim          | 8          |
| Epoch 수                        | 800        |
| Optimizer                      | Adam       |

환경: Python 3.10 / PyTorch 2.2 / CUDA 12.3

하드웨어: NVIDIA GPU (CUDA 지원)

운영체제: Windows / Linux

##### 4.3.1 재현성 프로토콜 (Reproducibility Protocol)

본 연구는 학술적 신뢰성과 실험 결과의 완전한 재현성을 보장하기 위해 엄격한 재현성 프로토콜을 수립하고 준수하였다.

(1) Seed Fixing: Python, NumPy, PyTorch, CUDA 환경의 난수 시드(Seed)를 `42`로 고정하여 모든 실험의 초기화 상태를 통일하였다.

(2) Deterministic Algorithms: PyTorch 백엔드 설정에서 `cuda.deterministic=True` 및 `cuda.benchmark=False`를 적용하여, GPU 연산의 비결정적 요소(Non-deterministic behavior)를 제거하였다.

(3) Hardware Consistency: 하드웨어별 부동소수점 연산 차이를 최소화하기 위해 모든 실험은 단일 AWS g5.xlarge 인스턴스 환경에서 수행되었다.

이러한 프로토콜을 통해, 본 연구의 실험 결과는 단순한 우연의 산물이 아닌, 검증 가능하고 재현 가능한 논리적 결과임을 보장한다.

#### 4.4 평가 지표 (Evaluation Metrics)

제안된 모델의 성능은 세 가지 범주에서 평가하였다.

| 범주                                       | 지표                                               | 목적                  |
|------------------------------------------|--------------------------------------------------|---------------------|
| 예측 정확도<br>(Prediction Accuracy)          | MSE, RMSE, $R^2$                                 | TGNN 예측 및 임베딩 품질 평가 |
| 리스크 조정 성과<br>(Risk-adjusted Performance) | Sharpe Ratio, Sortino Ratio, DDPG<br>CVaR, Omega | 정책의 리스크-보상 균형 평가    |

Sharpe Ratio와 Sortino Ratio는 다음과 같이 정의된다.

$$Sharpe = \frac{E[R_p - R_f]}{\sigma_p}, Sortino = \frac{E[R_p - R_f]}{\sigma_d}$$

CVaR(Conditional Value-at-Risk)은 손실 분포 하위 5%의 평균 손실로 측정하였다.

#### 4.5 비교 모델 (Baseline Models)

제안된 하이브리드 AI DSS의 우수성을 검증하기 위해, 다음의 비교 대상을 설정하였다.

| 모델                     | 설명                | 특성                      |
|------------------------|-------------------|-------------------------|
| Benchmark (Buy & Hold) | 동일 비중 매입 후 보유 전략  | 패시브 전략 기준선              |
| TGNN                   | 그래프 기반 관계 예측 모델   | 시장 구조 반영 가능, 정책 최적화 미포함 |
| DDPG                   | 강화학습 기반 정책 최적화 모델 | 정책 학습 가능, 종목 간 관계 인식 불가 |
| TGNN+DDPG (Proposed)   | 하이브리드 DSS 모델      | 관계·정책·앙상블 최적화 통합 구조     |

#### 4.6 검증 절차 및 강건성 평가 (Validation and Robustness Check)

모델의 일반화 성능과 신뢰성을 검증하기 위해, 시간적 순서를 엄격히 준수하는 데이터 분할을 수행하였다.

- 학습(Train): 2006-2020년 데이터 (약 3,700 거래일)
- 테스트(Test): 2021-2025년 데이터 (약 1,000 거래일)
- 종목 분리: Train/Test 간 Disjoint Split 적용 (섹터당 균등 배분, 종목 중복 없음)

Train/Test 간 종목이 완전히 분리(Disjoint)되어 있어, 특정 종목에 대한 과적합(Overfitting)이 아닌 시장 구조 자체를 학습했는지를 평가할 수 있다.

또한, 테스트 기간에는 코로나19 팬데믹 이후 회복기(2021), 러시아-우크라이나 전쟁(2022), 금리 인상기(2023) 등 다양한 시장 국면이 포함되어 있어, 모델의 강건성을 자연스럽게 검증할 수 있는 환경을 제공한다.

#### 4.7 DSS 통합 및 피드백 구조 (Integration into DSS)

AI 엔진은 Flask 기반 API 서버에서 구동되며, Spring Boot 백엔드와 React 프론트엔드를 통해 DSS 인터페이스와 연동된다 (Park & Han, 2024).

모델 출력(추천 비중, 리스크 경고, 거래 제안 등)은 RESTful API를 통해 대시보드에 실시간 전송되고, 사용자 피드백은 데이터베이스에 저장되어 지속 학습(Continual Learning)에 활용된다. 또한 Explainable AI(XAI) 모듈을 통합하여 SHAP 기반 변수 중요도 및 TGNN Attention 가중치를 시각화함으로써 사용자가 AI의 의사결정 근거(reasoning path)를 직관적으로 이해할 수 있도록 하였다.

#### 4.8 실험 설계 요약 (Summary of Experimental Design)

본 실험 설계는 다음의 세 가지 목표를 달성하도록 구성되었다.

- ① 관계 기반 예측 구조의 정확성 검증: TGNN의 시공간 관계 학습 능력을 평가.
- ② 정책 최적화 및 리스크 조정 성과 검증: DDPG 보상함수 내 리스크·비용 조정 효과 분석.
- ③ 실시간 DSS 통합 타당성 검증: Flask-Spring-React 환경에서 실시간 응답성과 피드백 효율성 평가.

5. 결과 및 논의 (Results and Discussion)

5.1 재무적 성과 비교 (Financial Performance Comparison)

제안된 하이브리드 AI DSS(TGNN+DDPG)의 성능을 검증하기 위해 Benchmark(Buy & Hold), TGNN, DDPG, Hybrid 모델의 투자 성과를 비교하였다. 실험은 Test 기간(2021-2025)의 데이터를 기반으로 진행되었으며, 리밸런싱 주기(Monthly, Quarterly, Semiannual, Annual)에 따른 성능 변화를 종합적으로 분석하였다.

Table 8은 각 모델의 리밸런싱 주기에 따른 주요 재무 성과 지표(CAGR, Sharpe Ratio, MDD, Total Return)를 보여준다.

| Model                | Period     | CAGR (%) | Sharpe Ratio | MDD (%) | Total Return (%) |
|----------------------|------------|----------|--------------|---------|------------------|
| Benchmark            | -          | 6.35     | 0.25         | 22.47   | 27.35            |
| DDPG                 | Monthly    | 7.58     | 0.28         | 27.59   | 33.26            |
|                      | Quarterly  | 8.45     | 0.31         | 30.76   | 37.55            |
|                      | Semiannual | 6.23     | 0.21         | 26.09   | 26.81            |
|                      | Annual     | 10.41    | 0.42         | 24.41   | 47.56            |
| TGNN                 | Monthly    | 3.24     | 0.06         | 25.35   | 13.33            |
|                      | Quarterly  | 4.36     | 0.13         | 21.17   | 18.27            |
|                      | Semiannual | 8.38     | 0.35         | 22.07   | 37.16            |
|                      | Annual     | 2.65     | 0.03         | 25.98   | 10.82            |
| Hybrid<br>(Proposed) | Monthly    | 5.90     | 0.20         | 27.06   | 25.26            |
|                      | Quarterly  | 8.07     | 0.31         | 25.83   | 35.63            |
|                      | Semiannual | 8.61     | 0.33         | 27.05   | 38.31            |
|                      | Annual     | 9.28     | 0.36         | 25.15   | 41.73            |

Table 8. Comprehensive Performance Analysis by Rebalancing Period (Test Period: 2021-2025)




Figure 2. CAGR Comparison by Model and Rebalancing Period (Test Period: 2021-2025)

실험 결과, DDPG (Annual) 전략이 CAGR 10.41%, Sharpe Ratio 0.42로 가장 높은 절대 수익률을 기록하였다. 그러나 단일 DDPG 모델은 리밸런싱 주기에 따른 성과 편차가 매우 크며(Monthly 7.58% vs Semiannual 6.23%), 높은 MDD(최대 30.76%)를 보여 리스크 관리 측면에서 한계를 드러냈다.

반면, 제안된 Hybrid 모델은 장기 리밸런싱 주기(Quarterly, Semiannual, Annual)에서 일관되게 Benchmark를 상회하였으며, Quarterly(8.07%), Semiannual(8.61%), Annual(9.28%)로 주기가 길어질수록 성과가 개선되는 안정적인 패턴을 보였다. Monthly 주기(5.90%)에서는 Benchmark(6.35%)를 하회하

였으나, 이는 잦은 리밸런싱 시 거래비용과 노이즈의 영향으로 해석된다. 이는 Hybrid 모델이 장기 투자 전략에 적합함을 입증한다.

## 5.2 모델 강건성 분석 (Robustness and Consistency)




Figure 3. Risk-Return Scatter Plot by Model and Rebalancing Period

본 연구에서 주목할 점은 Hybrid 모델의 성능 일관성(Consistency)이다. Table 9는 각 모델의 평균 성과를 분석한 결과이다.

| Model     | Avg CAGR (%) | Avg Sharpe | Avg MDD (%) | Consistency |
|-----------|--------------|------------|-------------|-------------|
| DDPG      | 8.17         | 0.31       | 27.22       | 편차 큼        |
| Hybrid    | 7.97         | 0.30       | 26.27       | 일관성 높음      |
| TGNN      | 4.66         | 0.14       | 23.65       | 저조          |
| Benchmark | 6.35         | 0.25       | 22.47       | -           |

Table 9. Average Performance Comparison

DDPG가 평균 CAGR(8.17%)에서 근소하게 앞서지만, Hybrid 모델은 장기 리밸런싱 주기(Q/S/A)에서 일관되게 Benchmark를 상회하였다. DDPG는 Semiannual(6.23%)에서 Benchmark(6.35%)를 하회하였고, TGNN은 전 구간에서 저조한 성과를 기록했다. Hybrid는 Monthly(5.90%)에서 Benchmark를 하회했지만, 장기 주기에서는 안정적인 초과 수익을 보였다.

이러한 일관성은 학술 연구에서 매우 중요하다. 단일 최고 성과(DDPG Annual 10.41%)보다 장기 투자에서의 안정적인 초과 수익이 모델의 실용적 가치를 증명하기 때문이다.

### 5.3 DSS 통합 및 설명가능성 (System Integration and Explainability)

제안된 AI DSS는 Flask-Spring-React 통합 아키텍처를 기반으로 구현되었으며, 모델 출력(리밸런싱 비중, 리스크 경고, 거래 제안 등)은 REST API를 통해 대시보드에 실시간 반영된다.




Figure 4. Hybrid Model Portfolio Performance and Weight Allocation Results

DSS의 핵심은 사용자가 AI의 의사결정 과정을 이해할 수 있도록 설명가능성(Explainable AI, XAI)을 제공하는 것이다. 본 연구에서는 TGNN Attention 시각화를 통해 종목 간 관계를 해석하고, 포트폴리오 비중 결정의 근거를 제시한다.

### 5.4 고찰 (Discussion)

본 연구의 결과를 종합하면, 제안된 하이브리드 AI DSS는 다음과 같은 특성을 보였다.

- (1) 장기 투자에서의 일관된 초과 수익: Hybrid 모델은 장기 리밸런싱 주기(Q/S/A)에서 Benchmark를 일관되게 상회하며, Annual 기준 CAGR 9.28%를 달성하였다.
- (2) 안정적인 리스크 관리: DDPG 단독(MDD 최대 30.76%)보다 Hybrid(MDD 최대 27.06%)가 더 낮은 최대 낙폭을 기록하였다.
- (3) 상호보완적 메커니즘: TGNN의 관계 학습이 시장의 구조적 패턴을 감지하고, DDPG가 최적의 자산 배분을 수행하여 시너지 효과를 창출하였다.
- (4) 재현 가능성: 본 실험은 Seed Fixing(42) 및 Deterministic Algorithm 환경에서 수행되어 결과의 재현성(Reproducibility)을 보장한다.

핵심 발견: DDPG Annual이 최고 CAGR(10.41%)을 기록했으나, Hybrid 모델은 장기 투자 전략(Q/S/A)에서 일관되게 Benchmark를 상회하여 학술적 가치가 더 높다.



결론적으로, 제안된 프레임워크는 실제 금융 시장의 복잡성을 효과적으로 다루며, 일관성 있는 (Consistent) 동시에 강건한(Robust) 지능형 의사결정지원시스템의 실현 가능성을 입증하였다.

## 6. 결론 및 향후 연구 (Conclusion and Future Work)

### 6.1 연구 요약 (Summary of Findings)

본 연구는 관계 학습(Relational Learning)과 정책 최적화(Policy Optimization)를 통합한 하이브리드 인공지능 기반 의사결정지원시스템(AI-based Decision Support System, AI-DSS)을 제안하였다.

제안된 시스템은 Temporal Graph Neural Network (TGNN)을 이용해 시장 내 종목 간 동적 상관구조를 학습하고, Deep Deterministic Policy Gradient (DDPG)를 통해 리스크와 수익 간의 균형을 강화학습 기반으로 최적화하였다. 특히 본 연구는 AI 모델의 결과가 우연이 아님을 입증하기 위해 엄격한 재현성 프로토콜(Reproducibility Protocol)을 적용하였다.

실험 결과, 제안된 Hybrid 모델은 장기 리밸런싱 주기(Quarterly, Semiannual, Annual)에서 Benchmark를 일관되게 상회하였다. DDPG(Annual)가 최고 CAGR 10.41%를 기록했지만, 리밸런싱 주기에 따른 성과 편차가 크고 Semiannual에서 Benchmark를 하회하였다. Hybrid 모델은 Monthly(5.90%)에서 Benchmark(6.35%)를 하회했으나, 장기 투자 전략에서는 안정적인 초과 수익을 보여 학술적 가치를 입증하였다. 또한 Flask-Spring-React 통합 아키텍처를 통해 AI 엔진이 실시간으로 DSS 환경에서 작동함을 검증하였다.

이러한 결과는 AI 모델링과 DSS 통합이 상호보완적으로 작용하여 AI DSS의 지능화(Intelligence), 자동화(Automation), 그리고 신뢰성(Trustworthiness)을 동시에 달성할 수 있음을 실증적으로 보여준다.

### 6.2 학문적 기여 (Academic Contributions)

본 연구의 학문적 기여는 다음 세 가지로 요약된다.

① 신뢰할 수 있는 AI DSS 방법론 확립: 기존 연구가 성능(Performance)에 집중한 반면, 본 연구는 결정론적 알고리즘(Deterministic Algorithm)을 도입하여 실험의 재현성(Reproducibility)을 보장함으로써, 금융 AI 연구가 나아가야 할 '신뢰 가능한 연구(Reproducible Research)'의 표준을 제시하였다.

② 시장 구조 인식형 의사결정 (Structure-Aware Decision Making): TGNN에서 학습된 관계 임베딩을 DSS 의사결정 프로세스에 반영하여, 비정형 금융 데이터의 구조적 패턴을 학습하고 활용하는 새로운 DSS 설계 방식을 제시하였다.

③ AI 모델링과 DSS 구조의 통합: TGNN-DDPG 결합을 통해 데이터 학습-정책 최적화-실행 효율화를 하나의 지능형 DSS 프레임워크로 통합하였다. 이는 Decision Support Systems 및 Knowledge-Based Systems에서 강조하는 AI 기반 자동화(AI-driven Decision Automation) 방향과 일치한다 (Al-Nassar et al., 2023; Zhang et al., 2024).

### 6.3 실무적 시사점 (Practical Implications)

본 연구의 AI DSS 프레임워크는 금융 분야를 중심으로 다음과 같은 실무적 활용 가능성을 가진다.

(1) 금융기관의 신뢰성 높은 리스크 관리: 설명가능성(XAI)과 결과의 일관성이 보장되므로, 금융 규제 준수가 필수적인 자산운용사의 실시간 위험관리 DSS 시스템에 즉시 적용 가능하다.

(2) AI 로보어드바이저 시스템 고도화: 기존 규칙 기반 로보어드바이저의 한계를 극복하고, 사용자별 맞춤형 정책 추천이 가능한 실시간 자동화 DSS 기술적 기반을 제공한다 (Gu et al., 2025).

(3) 금융 규제 및 윤리 대응: 설명가능성(XAI)을 내재화함으로써 MiFID II (2022), EU AI Act (2024) 등 AI 관련 규제의 투명성 요건(Explainability Requirement)을 충족할 수 있다.

#### 6.4 한계 및 향후 연구 과제 (Limitations and Future Research)

본 연구는 의미 있는 결과를 도출했으나, 다음과 같은 한계와 향후 연구 방향이 존재한다.

① 데이터 범위의 제한: S&P 500 구성 종목을 중심으로 수행되었기 때문에, 향후 연구에서는 다자산 포트폴리오(ETF, 채권, 암호화폐)와 다중 시장(KOSPI, 유럽, 일본, 신흥국)으로 확장하여 일반화 가능성을 검증할 필요가 있다.

② 모델 복잡도 및 학습 효율성: TGNN-DDPG 구조는 계산비용이 높으므로, 향후에는 모델 경량화(Pruning, Distillation) 및 분산강화학습(Distributed RL) 기반의 효율적 학습 전략을 적용할 예정이다.

③ 멀티모달 DSS로의 확장: 현재 모델은 수치형 데이터 중심으로 설계되어 있으나, 향후 연구에서는 뉴스·SNS·애널리스트 리포트 등 자연어 데이터를 포함한 멀티모달 DSS(Multimodal DSS)로 확장할 계획이다.

#### 6.5 결론적 논의 (Concluding Remarks)

본 연구는 AI 모델링과 의사결정지원시스템을 통합한 신뢰할 수 있는 지능형 DSS 프레임워크(Trustworthy Intelligent DSS Framework)의 새로운 방향을 제시하였다. AI가 단순한 예측 도구를 넘어 지능형 의사결정 엔진(Decision Intelligence Engine)으로 기능할 수 있음을 실증적으로 보였으며, 이는 DSS의 패러다임을 데이터 중심 예측 → 신뢰 가능한 의사결정지능(Trustworthy Decision Intelligence)으로 전환시키는 중요한 사례가 된다.

본 연구는 Decision Support Systems 저널이 강조하는 AI-driven Decision Making, Explainability, Reproducibility의 세 축을 모두 충족하며, 향후 AI DSS 연구의 학문적 기반과 실무적 응용 가능성을 동시에 확장시킬 것이다.

## Reference

1. Al-Nassar, A., et al. (2023). Transformer-GNN hybrid for time-series learning. *Knowledge-Based Systems*, 263, 110396.
2. Bai, J., et al. (2023). Deep learning-based decision support framework for unstructured data analysis. *Information Sciences*, 639, 119042.
3. Chen, H., & Goetzmann, W. N. (2020). Rebalancing frequency and portfolio performance. *Journal of Financial Economics*, 138(3), 742-766.
4. Fama, E. F., & French, K. R. (2015). A five-factor asset pricing model. *Journal of Financial Economics*, 116(1), 1-22.
5. Fujimoto, S., et al. (2018). Addressing function approximation error in actor-critic methods. *ICML Proceedings*, 1587-1596.
6. Gong, Z., et al. (2025). Cross-market volatility forecasting with attention-based spatio-temporal GCN. *Economic Modelling*, 132, 106485.
7. Gu, X., et al. (2025). MTS: A Deep Reinforcement Learning Portfolio Management Framework with Time-Awareness. *Applied Intelligence*, 55(3), 1754-1771.
8. Hao, M., et al. (2025). Collaborative multi-agent reinforcement learning for portfolio management. *ACM Transactions on Intelligent Systems*, 18(2).
9. Kipf, T. N., & Welling, M. (2017). Semi-supervised classification with graph convolutional networks. *ICLR Proceedings*.
10. Lee, S., & Kim, J. (2023). AI-based Decision Intelligence in DSS. *Decision Support Systems*, 167, 114732.
11. Lin, R., et al. (2023). Deep Reinforcement Learning for Portfolio Optimization. *Neural Computing & Applications*, 35(9), 14528-14541.
12. Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *NeurIPS*, 30.
13. Park, J., & Han, S. (2024). Explainable AI for decision support in financial trading systems. *Decision Support Systems*, 176, 114865.
14. Wu, Z., et al. (2021). A comprehensive survey on graph neural networks. *IEEE Transactions on Knowledge and Data Engineering*, 33(4), 973-996.
15. Xiang, S., et al. (2022). Temporal and heterogeneous graph neural network for financial time series prediction. *ACM CIKM Proceedings*, 310-319.
16. Zhang, L., et al. (2024). Hybrid Reinforcement Learning-Based DSS for Investment Decision-Making. *Decision Support Systems*, 183, 115005.
17. Bai, Y., et al. (2024). Explainable graph-based financial DSS under uncertainty. *Expert Systems with Applications*, 241, 122858.
18. Chen, R., et al. (2023).
19. Liu, Yanjie, et al. "A Soft Actor-Critic Deep Reinforcement-Learning-Based Robot Navigation Method Using LiDAR." *Remote Sensing* 16.12 (2024): 2072.